

# TEHNICI DE OPTIMIZARE

## Curs 1

Andrei Pătrașcu

Departament Informatică  
Universitatea din Bucureşti

Orar:

- În săptămânilor impare se face seminar
- În săptămânilor pare se face laborator

Punctaj:

- Examen final scris - 50%
- Teme laborator - 40% (**Prezență obligatorie!**)
- Activitate (și prezență) seminar - 10%
- **Promovare:** nota minim 5 la examen final, nota minim 5 la temele de laborator



- B. Polyak, Introduction to Optimization, Optimization Software Inc., New York, 1987
- D. Bertsekas, Nonlinear Programming, Third Edition. Athena Scientific, 2016.
- Y. Nesterov, Introductory Lectures on Convex Optimization, Kluwer, 2004.
- Hiriart-Urruty, Jean-Baptiste, and Claude Lemaréchal. *Convex analysis and minimization algorithms I: Fundamentals*. Vol. 305. Springer science & business media, 1996.



≈ 850 î. Hr. Problema reginei Dido (a Cartaginei): Care este aria maximă a unei suprafețe de pământ delimitate cu o sfoară de lungime fixă?



outschool.com



≈ 850 î. Hr. Problema reginei Dido (a Cartaginei): Care este aria maximă a unei suprafețe de pământ delimitate cu o sfoară de lungime fixă?

$\max_{\text{curba}} \text{Arie}(\text{curba})$  supus la  $\text{Lungime}(\text{curba}) = ct.$

- În plan se cunoaște:  $4\pi A \leq L^2$  pentru toate curbele închise
- egalitate doar pentru cerc.



**sec. XVII-XVIII** Bernoulli, Leibniz, Newton, L'Hopital publică soluții ale câtorva probleme de calcul modelate prin căutarea de maxime/minime:

- forma optimă a unei nave cu rezistență minimă (Newton)
- curba celei mai rapide coborâri (Bernoulli)
- calcul variațional (Euler)
- sisteme liniare de ecuații (Gauss)



**sec. XIX-XX** Se conturează domeniul programării liniare: G. Dantzig investighează soluții ale sistemelor liniare de inegalități pentru probleme logistice ale Pentagon-ului.




[lclub-mathematicians.blogspot.com](http://lclub-mathematicians.blogspot.com)



### '60-'70 se dezvoltă programarea neliniară


- R.T. Rockafeller: "The original idea of "programming" was synonymous with optimization. The only way programming turned out to be computer programming as we know it now is that programming was connected with running or managing a government program on a computer. Early examples, like food distribution programs, very much involved optimization in the sense that finding the best way to do a job, and computer were essential for that. It was then called computer programming."



<https://sites.math.washington.edu/rtr/mypage.html>



**70'- prezent** - se dezvoltă Programarea (Optimizarea) Convexă



[eurasip.org](http://eurasip.org), [coe.gatech.edu](http://coe.gatech.edu), [fullcircle.asu.edu](http://fullcircle.asu.edu)



Modele (probleme) de optimizare:

- **Discretă:** căutare în domeniu discret

$$\begin{aligned} & \min (x_1 + x_2)^2 \\ \text{s.t. } & x_1 \in \{0, 1\} \\ & x_2 \in \{0, 1\} \end{aligned}$$



Modele (probleme) de optimizare:

- **Discretă:** căutare în domeniu discret

$$\begin{aligned} & \min (x_1 + x_2)^2 \\ \text{s.t. } & x_1 \in \{0, 1\} \\ & x_2 \in \{0, 1\} \end{aligned}$$

- Continuă: căutare într-un domeniu continuu

$$\begin{aligned} & \min (x_1 + x_2)^2 \\ \text{s.t. } & 0 \leq x_1 \leq 1 \\ & 0 \leq x_2 \leq 1 \end{aligned}$$



$$\begin{aligned} \min f(x) &:= (x_1 + x_2)^2 \\ \text{s.t. } x_1 &\in \{0, 1\} \\ x_2 &\in \{0, 1\} \end{aligned}$$

- Căutarea optimului se realizează (în general) prin verificarea unui număr finit de puncte ale mulțimii fezabile



$$\begin{aligned} \min f(x) &:= (x_1 + x_2)^2 \\ \text{s.t. } x_1 &\in \{0, 1\} \\ x_2 &\in \{0, 1\} \end{aligned}$$

- Căutarea optimului se realizează (în general) prin verificarea unui număr finit de puncte ale mulțimii fezabile
- Mulțimea fezabilă include 4 puncte:  $\begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \end{bmatrix}$



$$\begin{aligned} \min f(x) &:= (x_1 + x_2)^2 \\ \text{s.t. } x_1 &\in \{0, 1\} \\ x_2 &\in \{0, 1\} \end{aligned}$$

- Căutarea optimului se realizează (în general) prin verificarea unui număr finit de puncte ale mulțimii fezabile
- Mulțimea fezabilă include 4 puncte:  $\begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \end{bmatrix}$
- $f\left(\begin{bmatrix} 1 \\ 1 \end{bmatrix}\right) = 4, f\left(\begin{bmatrix} 0 \\ 1 \end{bmatrix}\right) = 1, f\left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}\right) = 1, f\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}\right) = 0$




$$\begin{aligned} \min f(x) &:= (x_1 + x_2)^2 \\ \text{s.t. } x_1 &\in \{0, 1\} \\ x_2 &\in \{0, 1\} \end{aligned}$$

- Căutarea optimului se realizează (în general) prin verificarea unui număr finit de puncte ale mulțimii fezabile
- Mulțimea fezabilă include 4 puncte:  $\begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \end{bmatrix}$
- În general, numărul de puncte ale mulțimii fezabile crește exponențial cu dimensiunea problemei



**Problema comis-voiajorului:** Pentru o listă dată de orașe și distanțe între acestea, care este cea mai scurtă rută posibilă ce trece prin fiecare oraș exact o singură dată și se întoarce la origine?



Distanța între  $i$  și  $j$  notăm  $d_{ij}$ , variabila  $x_{ij}$  este indicator pentru includerea  $(i, j)$  în ruta optimă:

$$\min_x \sum_{i=1}^n \sum_{i \neq j, j=1}^n d_{ij} x_{ij}$$

s.t.  $x_{ij} \in \{0, 1\} \quad \forall i, j$

$$\sum_{i, i \neq j} x_{ij} = 1 \quad \forall i$$

$$\sum_{j, i \neq j} x_{ij} = 1 \quad \forall j$$

- căutare "brute-force":  $\mathcal{O}(n!)$  (complexitate exponențială)



Distanța între  $i$  și  $j$  notăm  $d_{ij}$ , variabila  $x_{ij}$  este indicator pentru includerea  $(i, j)$  în ruta optimă:

$$\min_x \sum_{i=1}^n \sum_{i \neq j, j=1}^n d_{ij} x_{ij}$$

s.t.  $x_{ij} \in \{0, 1\} \quad \forall i, j$

$$\sum_{i, i \neq j} x_{ij} = 1 \quad \forall i$$

$$\sum_{j, i \neq j} x_{ij} = 1 \quad \forall j$$

- căutare "brute-force":  $\mathcal{O}(n!)$  (complexitate exponențială)
- programare dinamică:  $\mathcal{O}(n^2 2^n)$



Distanța între  $i$  și  $j$  notăm  $d_{ij}$ , variabila  $x_{ij}$  este indicator pentru includerea  $(i, j)$  în ruta optimă:

$$\min_x \sum_{i=1}^n \sum_{i \neq j, j=1}^n d_{ij} x_{ij}$$

$$\text{s.t. } x_{ij} \in \{0, 1\} \quad \forall i, j$$

$$\sum_{i, i \neq j} x_{ij} = 1 \quad \forall i$$

$$\sum_{j, i \neq j} x_{ij} = 1 \quad \forall j$$

- căutare "brute-force":  $\mathcal{O}(n!)$  (complexitate exponențială)
- programare dinamică:  $\mathcal{O}(n^2 2^n)$
- TSPLIB (1991), cea mai mare problemă rezolvată  $n = 85,900$



Distanța între  $i$  și  $j$  notăm  $d_{ij}$ , variabila  $x_{ij}$  este indicator pentru includerea  $(i, j)$  în ruta optimă:

$$\min_x \sum_{i=1}^n \sum_{i \neq j, j=1}^n d_{ij} x_{ij}$$

s.t.  $x_{ij} \in \{0, 1\} \quad \forall i, j$

$$\sum_{i, i \neq j} x_{ij} = 1 \quad \forall i$$

$$\sum_{j, i \neq j} x_{ij} = 1 \quad \forall j$$

- căutare "brute-force":  $\mathcal{O}(n!)$  (complexitate exponențială)
- programare dinamică:  $\mathcal{O}(n^2 2^n)$
- TSPLIB (1991), cea mai mare problemă rezolvată  $n = 85,900$
- $n = \mathcal{O}(10^6)$  suboptimalitate 3%



Modele (probleme) de optimizare:

- Discretă: căutare în domeniu discret

$$\begin{aligned} & \min (x_1 + x_2)^2 \\ \text{s.t. } & x_1 \in \{0, 1\} \\ & x_2 \in \{0, 1\} \end{aligned}$$


- Continuă: căutare într-un domeniu continuu

$$\begin{aligned} & \min (x_1 + x_2)^2 \\ \text{s.t. } & 0 \leq x_1 \leq 1 \\ & 0 \leq x_2 \leq 1 \end{aligned}$$




$$\begin{aligned} \min \quad & f(x) := (x_1 + x_2)^2 \\ \text{s.t. } & 0 \leq x_1 \leq 1 \\ & 0 \leq x_2 \leq 1 \end{aligned}$$

- Mulțimea fezabilă este un poliedru convex:



$$\begin{aligned} \min \quad & f(x) := (x_1 + x_2)^2 \\ \text{s.t. } & 0 \leq x_1 \leq 1 \\ & 0 \leq x_2 \leq 1 \end{aligned}$$

- Mulțimea fezabilă este un poliedru convex:




desmos.com

- Aproximarea optimului se realizează prin execuția unui algoritm iterativ



$$\begin{aligned} \min \quad & f(x) := (x_1 + x_2)^2 \\ \text{s.t.} \quad & 0 \leq x_1 \leq 1 \\ & 0 \leq x_2 \leq 1 \end{aligned}$$

- Mulțimea fezabilă este un poliedru convex:



- Aproximarea optimului se realizează prin execuția unui algoritm iterativ
- $x^* = \pi_{[0,1]^2}(x^* - \nabla f(x^*)) \Leftrightarrow \begin{bmatrix} x_1^* \\ x_2^* \end{bmatrix} = \begin{bmatrix} \pi_{[0,1]}(-x_2^*) \\ \pi_{[0,1]}(-x_1^*) \end{bmatrix} \Leftrightarrow x^* = 0$



**Problema comis-voiajorului:** Pentru o listă dată de orașe și distanțe între acestea, care este cea mai scurtă rută posibilă ce trece prin fiecare oraș exact o singură dată și se întoarce la origine?

$$\min_x \sum_{i=1}^n \sum_{i \neq j, j=1}^n d_{ij} x_{ij}$$

$$\text{s.t. } x_{ij} \in [0, 1] \quad \forall i, j$$

$$\sum_{i, i \neq j} x_{ij} = 1 \quad \forall i$$

$$\sum_{j, i \neq j} x_{ij} = 1 \quad \forall j$$



**Problema comis-voiajorului:** Pentru o listă dată de orașe și distanțe între acestea, care este cea mai scurtă rută posibilă ce trece prin fiecare oraș exact o singură dată și se întoarce la origine?

$$\min_x \sum_{i=1}^n \sum_{i \neq j, j=1}^n d_{ij} x_{ij}$$

$$\text{s.t. } x_{ij} \in [0, 1] \quad \forall i, j$$

$$\sum_{i, i \neq j} x_{ij} = 1 \quad \forall i$$

$$\sum_{j, i \neq j} x_{ij} = 1 \quad \forall j$$

- relaxarea convexă a TSP: soluția nu coincide cu soluția TSP!



**Problema comis-voiajorului:** Pentru o listă dată de orașe și distanțe între acestea, care este cea mai scurtă rută posibilă ce trece prin fiecare oraș exact o singură dată și se întoarce la origine?

$$\min_x \sum_{i=1}^n \sum_{i \neq j, j=1}^n d_{ij} x_{ij}$$

$$\text{s.t. } x_{ij} \in [0, 1] \quad \forall i, j$$

$$\sum_{i, i \neq j} x_{ij} = 1 \quad \forall i$$

$$\sum_{j, i \neq j} x_{ij} = 1 \quad \forall j$$

- relaxarea convexă a TSP: soluția nu coincide cu soluția TSP!
- problemă de *programare liniară* (convexă)



**Problema comis-voiajorului:** Pentru o listă dată de orașe și distanțe între acestea, care este cea mai scurtă rută posibilă ce trece prin fiecare oraș exact o singură dată și se întoarce la origine?

$$\min_x \sum_{i=1}^n \sum_{i \neq j, j=1}^n d_{ij} x_{ij}$$

$$\text{s.t. } x_{ij} \in [0, 1] \quad \forall i, j$$

$$\sum_{i, i \neq j} x_{ij} = 1 \quad \forall i$$

$$\sum_{j, i \neq j} x_{ij} = 1 \quad \forall j$$

- relaxarea convexă a TSP: soluția nu coincide cu soluția TSP!
- problemă de *programare liniară* (convexă)
- $\mathcal{O}(n^3)$  (1987),  $\mathcal{O}(n^{2.5})$  (1989)



**Problema comis-voiajorului:** Pentru o listă dată de orașe și distanțe între acestea, care este cea mai scurtă rută posibilă ce trece prin fiecare oraș exact o singură dată și se întoarce la origine?

$$\min_x \sum_{i=1}^n \sum_{i \neq j, j=1}^n d_{ij} x_{ij}$$

$$\text{s.t. } x_{ij} \in [0, 1] \quad \forall i, j$$

$$\sum_{i, i \neq j} x_{ij} = 1 \quad \forall i$$

$$\sum_{j, i \neq j} x_{ij} = 1 \quad \forall j$$

- relaxarea convexă a TSP: soluția nu coincide cu soluția TSP!
- problemă de *programare liniară* (convexă)
- $\mathcal{O}(n^3)$  (1987),  $\mathcal{O}(n^{2.5})$  (1989)
- $\mathcal{O}\left(n^{2+\frac{1}{6}}\right)$  (Cohen et al., 2019),  $\mathcal{O}\left(n^{2+\frac{1}{18}}\right)$  (Jiang et al., 2020)



Model de optimizare cu constrângeri generale:

$$\begin{aligned} f^* := \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.t. } x \in Q. \end{aligned}$$

- $f$  se numește funcție obiectiv (cost)



Model de optimizare cu constrângeri generale:

$$\begin{aligned} f^* := \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.t. } x \in Q. \end{aligned}$$

- $f$  se numește funcție obiectiv (cost)
- $x$  variabila de căutare de dimensiune  $n$



Model de optimizare cu constrângeri generale:

$$\begin{aligned} f^* := \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.t. } x \in Q. \end{aligned}$$

- $f$  se numește funcție obiectiv (cost)
- $x$  variabila de căutare de dimensiune  $n$
- $Q$  se numește mulțime fezabilă. Definește mulțimea din  $\mathbb{R}^n$  în care se caută optimul.



Model de optimizare cu constrângeri generale:

$$\begin{aligned} f^* := \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.t. } x \in Q. \end{aligned}$$

- $f$  se numește funcție obiectiv (cost)
- $x$  variabila de căutare de dimensiune  $n$
- $Q$  se numește mulțime fezabilă. Definește mulțimea din  $\mathbb{R}^n$  în care se caută optimul.
- Format explicit:  $Q := \{x \in \mathbb{R}^n : g(x) \leq 0, h(x) = 0\}$




Model de optimizare cu constrângeri generale:

$$f^* := \min_{x \in \mathbb{R}^n} f(x)$$

s.t.  $x \in Q.$

Puncte de optim global:




desmos.com



Model de optimizare cu constrângeri generale:


$$\begin{aligned} f^* := \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.t. } x \in Q. \end{aligned}$$

Puncte de optim local:



Surse de zgomot în achiziții de semnal:

- perturbații senzori: factori fizici de mediu (e.g. temperatură)
- pierderi de date (comunicație)
- alterări de memorie




$$\min_{X \in \mathbb{R}^{m \times n}} \frac{1}{2} \|X - Y\|_F^2 + \lambda \mathcal{L}(X)$$

- $\mathcal{L}(\cdot)$  funcție de penalitate de filtrare (zgomot gaussian)
- $\mathcal{L}(X) = \sum_{i,j} (x_{i+1,j} - x_{i,j})^2 + (x_{i,j+1} - x_{i,j})^2$
- $\mathcal{L}(X) = \sum_{i,j} |x_{i+1,j} - x_{i,j}| + |x_{i,j+1} - x_{i,j}|$



# Detectie anomaliilor




<https://www.mathworks.com>



## Detectie anomalii

Model bazat pe centre:  $\min_{c \in \mathbb{R}^n} \sum_{i=1}^m \|c - y^i\|_2^2$

Model SVDD:  $\min_{c \in \mathbb{R}^n, R > 0} R^2$  s.t.  $\|c - y^i\|_2 \leq R$



- prelucrarea semnalelor: e.g. filtre
- statistică și învățare automată: e.g. detecție de anomalii
- inginerie: e.g. control automat și distribuit
- logistică și operațiuni: e.g. probleme de transport
- motoare de căutare: e.g. problema Google



- **O scurtă recapitulare**
- Convexitate: Mulțimi convexe
- Diferențabilitate
- Convexitate: Funcții convexe



**Vezi appendix!**



- O scurtă recapitulare
- **Convexitate: Mulțimi convexe**
- Diferențiabilitate
- Convexitate: Funcții convexe






## Definiție

Mulțimea  $Q$  este **convexă** dacă și numai dacă  $\forall x, y \in Q$

$$\alpha x + (1 - \alpha)y \in Q \quad \forall \alpha \in [0, 1].$$

Mai mult,  $Q$  este **închisă** dacă își conține toate punctele limită (frontiera).

Pe scurt: segmentul aflat între oricare două puncte ale mulțimii se află, de asemenea, în mulțime.



- punct e.g.  $\{0\}$





- punct e.g.  $\{0\}$
- dreapta/segment e.g.  $\mathbb{R}^1 : [0, \infty)$ ,  $\mathbb{R}^2 : \{x \in \mathbb{R}^2 : x_1 + x_2 = 0\}$





## Mulțimi convexe - exemple afine

- punct e.g.  $\{0\}$
- dreapta/segment e.g.  $\mathbb{R}^1 : [0, \infty)$ ,  $\mathbb{R}^2 : \{x \in \mathbb{R}^2 : x_1 + x_2 = 0\}$
- hiperplan  $\mathbb{R}^n : \{x \in \mathbb{R}^n : a^T x = b\}$




- punct e.g.  $\{0\}$
- dreapta/segment e.g.  $\mathbb{R}^1 : [0, \infty)$ ,  $\mathbb{R}^2 : \{x \in \mathbb{R}^2 : x_1 + x_2 = 0\}$
- hiperplan  $\mathbb{R}^n : \{x \in \mathbb{R}^n : a^T x = b\}$



- varietate liniară  $\mathbb{R}^n : \{x \in \mathbb{R}^n : Ax = b\}$




- semispațiu     $S(a, b) := \{x \in \mathbb{R}^n : a^T x \leq b\}$




## Mulțimi convexe - exemple

- semispațiu  $S(a, b) := \{x \in \mathbb{R}^n : a^T x \leq b\}$





- poliedru  $C := \{x \in \mathbb{R}^n : Ax \leq b\}$





## Mulțimi convexe - exemple

- simplex  $\Delta_n := \{x \in \mathbb{R}^n : x_1 + x_2 + \cdots + x_n = 1, x \geq 0\}$



## Mulțimi convexe - exemple



- simplex  $\Delta_n := \{x \in \mathbb{R}^n : x_1 + x_2 + \cdots + x_n = 1, x \geq 0\}$



- con e.g. e.g.  $\mathbb{R}_+ := [0, \infty)$ ,  $\mathbb{R}_+^n := \{x \in \mathbb{R}^n : x \geq 0\}$





- bila  $B(c, r) := \{x \in \mathbb{R}^n : \|x - c\| \leq r\}$ , e.g.  $c = 0, r = 1$





## Mulțimi convexe - exemple non-afine

- bila  $B(c, r) := \{x \in \mathbb{R}^n : \|x - c\| \leq r\}$ , e.g.  $c = 0, r = 1$




- elipsoid  $E(c, r, P) := \{x \in \mathbb{R}^n : (x - c)^T P(x - c) \leq r\}$ , e.g.

$$c = 0, r = 1, (\text{st.})P = \begin{bmatrix} 0.2 & 0.5 \\ 0.5 & 2 \end{bmatrix}; (\text{dr.})P = \begin{bmatrix} 0.2 & 0.5 & 0 \\ 0.5 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$



- con non-afin e.g. con Lorentz  $K_L := \{x \in \mathbb{R}^3 : x_1^2 + x_2^2 \leq x_3\}$



Fie  $C_1, C_2, \dots, C_m \subset \mathbb{R}^n$  mulțimi convexe închise.

- *Intersecția:* mulțimea  $C = \bigcap_{i=1}^m C_i$  este închisă și convexă



Fie  $C_1, C_2, \dots, C_m \subset \mathbb{R}^n$  mulțimi convexe închise.

- *Intersecția:* mulțimea  $C = \bigcap_{i=1}^m C_i$  este închisă și convexă
- *Produs cartezian:* mulțimea  $C = C_1 \times C_2 \times \dots \times C_m$  este închisă și convexă.



Fie  $C_1, C_2, \dots, C_m \subset \mathbb{R}^n$  mulțimi convexe închise.

- *Intersecția:* mulțimea  $C = \bigcap_{i=1}^m C_i$  este închisă și convexă
- *Produs cartezian:* mulțimea  $C = C_1 \times C_2 \times \dots \times C_m$  este închisă și convexă.
- *Componerea cu un operator afin:* fie  $A \in \mathbb{R}^{p \times n}, b \in \mathbb{R}^p$ , mulțimea  $C'_i = \{z \in C_i : Az = b\}$  este închisă și convexă.



- Un hiperplan (afin) reprezintă intersecția dintre două semi-spații

$$H(a, b) = \{x \in \mathbb{R}^n : \mathbf{a}^T x \leq b, \mathbf{a}^T x \geq b\} = S(\mathbf{a}, b) \cap S(-\mathbf{a}, -b)$$



- Un hiperplan (afin) reprezintă intersecția dintre două semi-spații

$$H(a, b) = \{x \in \mathbb{R}^n : \mathbf{a}^T x \leq b, \mathbf{a}^T x \geq b\} = S(\mathbf{a}, b) \cap S(-\mathbf{a}, -b)$$

- O varietate liniară reprezintă intersecția unui număr finit de hiperplane

$$V(A, b) = H(A_1, b_1) \cap H(A_2, b_2) \cap \cdots \cap H(A_m, b_m)$$



- Un hiperplan (afin) reprezintă intersecția dintre două semi-spații

$$H(a, b) = \{x \in \mathbb{R}^n : \mathbf{a}^T x \leq \mathbf{b}, \mathbf{a}^T x \geq \mathbf{b}\} = S(\mathbf{a}, \mathbf{b}) \cap S(-\mathbf{a}, -\mathbf{b})$$

- O varietate liniară reprezintă intersecția unui număr finit de hiperplane

$$V(A, b) = H(A_1, b_1) \cap H(A_2, b_2) \cap \cdots \cap H(A_m, b_m)$$

- Multimea simplex (unitate) este intersecția dintre un hiperplan și un con convex

$$\Delta_n := \{x \in \mathbb{R}^n : x_1 + x_2 + \cdots + x_n = 1, x \geq 0\} = H(\mathbf{e}, 1) \cap \mathbb{R}_+^n$$



- Un hiperplan (afin) reprezintă intersecția dintre două semi-spații

$$H(a, b) = \{x \in \mathbb{R}^n : \mathbf{a}^T x \leq b, \mathbf{a}^T x \geq b\} = S(\mathbf{a}, b) \cap S(-\mathbf{a}, -b)$$

- O varietate liniară reprezintă intersecția unui număr finit de hiperplane

$$V(A, b) = H(A_1, b_1) \cap H(A_2, b_2) \cap \cdots \cap H(A_m, b_m)$$

- Multimea simplex (unitate) este intersecția dintre un hiperplan și un con convex

$$\Delta_n := \{x \in \mathbb{R}^n : x_1 + x_2 + \cdots + x_n = 1, x \geq 0\} = H(\mathbf{e}, 1) \cap \mathbb{R}_+^n$$

- Un poliedru reprezintă intersecția unui număr finit de semi-spații

$$\{x \in \mathbb{R}^n : Ax \leq b\} = S(A_1, b_1) \cap S(A_2, b_2) \cap \cdots \cap S(A_m, b_m)$$



Translațiile, intersecțiile și semi-spațiile sunt obiectele de bază în analiza convexă.

- $\{x \in \mathbb{R}^n : |a^T x + b| \leq r\}$



Translațiile, intersecțiile și semi-spațiile sunt obiectele de bază în analiza convexă.

- $\{x \in \mathbb{R}^n : |a^T x + b| \leq r\}$
- Hipercub:  $\{x \in \mathbb{R}^n : -1 \leq x \leq 1\}$



Translațiile, intersecțiile și semi-spațiile sunt obiectele de bază în analiza convexă.

- $\{x \in \mathbb{R}^n : |a^T x + b| \leq r\}$
- **Hipercub:**  $\{x \in \mathbb{R}^n : -1 \leq x \leq 1\}$
- $\{x \in \mathbb{R}^n : \|Ax\|_\infty \leq 1\}$



Translațiile, intersecțiile și semi-spațiile sunt obiectele de bază în analiza convexă.

- $\{x \in \mathbb{R}^n : |a^T x + b| \leq r\}$
- **Hipercub:**  $\{x \in \mathbb{R}^n : -1 \leq x \leq 1\}$
- $\{x \in \mathbb{R}^n : \|Ax\|_\infty \leq 1\}$
- $\{x \in \mathbb{R}^n : \|Ax\|_\infty \leq 1, \|x\|_2 \leq 1\}$



### Definiție

Fie  $Z = \{z^1, z^2, \dots, z^n\} \subset \mathbb{R}^n$ , pentru  $\alpha \in \Delta_n$  combinația  $\sum_i \alpha_i z^i$  se numește combinație convexă a punctelor din  $Z$ .



### Definiție

Fie  $Z = \{z^1, z^2, \dots, z^n\} \subset \mathbb{R}^n$ , pentru  $\alpha \in \Delta_n$  combinația  $\sum_i \alpha_i z^i$  se numește combinație convexă a punctelor din  $Z$ .

### Definiție (Reformulare)

Mulțimea  $Q \subset \mathbb{R}^n$  se numește convexă dacă pentru oricare set de puncte  $\{x^1, x^2, \dots, x^n\} \subset Q$  orice combinație convexă a punctelor din set rămâne în mulțimea  $Q$ .



### Definiție

Fie  $Z = \{z^1, z^2, \dots, z^n\} \subset \mathbb{R}^n$ , pentru  $\alpha \in \Delta_n$  combinația  $\sum_i \alpha_i z^i$  se numește combinație convexă a punctelor din  $Z$ .

### Definiție (Reformulare)

Mulțimea  $Q \subset \mathbb{R}^n$  se numește convexă dacă pentru oricare set de puncte  $\{x^1, x^2, \dots, x^n\} \subset Q$  orice combinație convexă a punctelor din set rămâne în mulțimea  $Q$ .

### Definiție

Fie  $Q \subset \mathbb{R}^n$  (nu neapărat convexă), acoperire convexă  $Q_h$  reprezintă cea mai "mică" mulțime convexă care include pe  $Q$ .

- O scurtă recapitulare
- Convexitate: Mulțimi convexe
- **Diferențiabilitate**
- Convexitate: Funcții convexe



Funcții scalare:  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  se numește diferențabilă în punctul  $x$  dacă  $\exists a \in \mathbb{R}^n$  astfel încât, pentru orice  $y \in \mathbb{R}^n$ :

$$f(x + y) = f(x) + a^T y + o(y)$$

- $a =: \nabla f(x)$  este *gradientul* funcției  $f$  în  $x$



Funcții scalare:  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  se numește diferențabilă în punctul  $x$  dacă  $\exists a \in \mathbb{R}^n$  astfel încât, pentru orice  $y \in \mathbb{R}^n$ :

$$f(x + y) = f(x) + a^T y + o(y)$$

- $a =: \nabla f(x)$  este *gradientul* funcției  $f$  în  $x$
- $\lim_{\|y\| \rightarrow 0} \frac{o(y)}{y} = 0$



Funcții scalare:  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  se numește diferențabilă în punctul  $x$  dacă  $\exists a \in \mathbb{R}^n$  astfel încât, pentru orice  $y \in \mathbb{R}^n$ :

$$f(x + y) = f(x) + a^T y + o(y)$$

- $a =: \nabla f(x)$  este *gradientul* funcției  $f$  în  $x$
- $\lim_{\|y\| \rightarrow 0} \frac{o(y)}{y} = 0$
- Pe scurt: funcția este diferențabilă în  $x$  dacă putem găsi o funcție liniară  $g(y) := f(x) + \nabla f(x)^T y$  astfel încât  $f(x + y) - g(y) = o(y)$



Funcții scalare:  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  se numește diferențabilă în punctul  $x$  dacă  $\exists a \in \mathbb{R}^n$  astfel încât, pentru orice  $y \in \mathbb{R}^n$ :

$$f(x + y) = f(x) + a^T y + o(y)$$


- $a =: \nabla f(x)$  este *gradientul* funcției  $f$  în  $x$
- $\lim_{\|y\| \rightarrow 0} \frac{o(y)}{y} = 0$
- Pe scurt: funcția este diferențabilă în  $x$  dacă putem găsi o funcție liniară  $g(y) := f(x) + \nabla f(x)^T y$  astfel încât  $f(x + y) - g(y) = o(y)$
- $\nabla f(\cdot)$  este unic determinat și definit de:  $\nabla f(x) := \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}$



Exemple:

- funcția liniară:  $f(x) = b^T x, \quad b \in \mathbb{R}^n$


$$\nabla f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$



Exemple:

- funcția pătratică:  $f(x) = \frac{1}{2}x^T Ax - b^T x$ , unde  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$

$$\nabla f(x) = Ax - b$$



[www.desmos.com](http://www.desmos.com)



Exemple:

- funcția pătratică:  $f(x) = \frac{1}{2}x^T Ax - b^T x$ , unde  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$

$$\nabla f(x) = Ax - b$$

$$\begin{aligned}f(x+y) &= \frac{1}{2}(x+y)^T A(x+y) - b^T(x+y) \\&= \frac{1}{2}x^T Ax - b^T x + (Ax - b)^T y + \frac{1}{2}y^T Ay \\&= f(x) + (Ax - b)^T y + \frac{1}{2}y^T Ay,\end{aligned}$$

Observați:  $\frac{1}{2}y^T Ay = o(y)$ .



## Definiție

O funcție  $f$  este continuă Lipschitz cu constanta  $L$  dacă satisface:

$$|f(x) - f(y)| \leq L\|x - y\| \quad \forall x, y$$

Echivalent orice funcție Lipschitz satisface  $\|\nabla f(x)\| \leq L \quad \forall x$ .

- $|x|$



## Definiție

O funcție  $f$  este continuă Lipschitz cu constanta  $L$  dacă satisface:

$$|f(x) - f(y)| \leq L\|x - y\| \quad \forall x, y$$

Echivalent orice funcție Lipschitz satisface  $\|\nabla f(x)\| \leq L \quad \forall x$ .

- $|x|$
- $\|x\|$



## Definiție

O funcție  $f$  este continuă Lipschitz cu constanta  $L$  dacă satisface:

$$|f(x) - f(y)| \leq L\|x - y\| \quad \forall x, y$$

Echivalent orice funcție Lipschitz satisface  $\|\nabla f(x)\| \leq L \quad \forall x$ .

- $|x|$
- $\|x\|$
- $\|Ax\|$



## Definiție

Prima derivată a funcției  $f$  este continuă Lipschitz cu constanța  $L$  dacă:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\| \quad \forall x, y$$

Echivalent, se exprimă:

$$\|\nabla^2 f(x)\| \leq L \quad \forall x$$

$$|f(x) - f(y) - \nabla f(y)^T(x - y)| \leq \frac{L}{2}\|x - y\|^2 \quad \forall x, y$$

- $\|x\|^2$



## Definiție

Prima derivată a funcției  $f$  este continuă Lipschitz cu constanța  $L$  dacă:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\| \quad \forall x, y$$

Echivalent, se exprimă:

$$\|\nabla^2 f(x)\| \leq L \quad \forall x$$

$$|f(x) - f(y) - \nabla f(y)^T(x - y)| \leq \frac{L}{2}\|x - y\|^2 \quad \forall x, y$$

- $\|x\|^2$
- $\|Ax\|^2$



Funcții scalare:  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  se numește *dublu diferențială în punctul  $x$*  dacă există matricea simetrică  $H \in \mathbb{R}^{n \times n}$  astfel încât, pentru orice  $y \in \mathbb{R}^n$ :

$$f(x + y) = f(x) + \langle \nabla f(x), y \rangle + \frac{1}{2} \langle Hy, y \rangle + o(\|y\|^2)$$

- $H =: \nabla^2 f(x)$  este *matricea derivatelor de ordin II sau Hessiana* funcției  $f$  în  $x$



Funcții scalare:  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  se numește *dublu diferențiabilă în punctul  $x$*  dacă există matricea simetrică  $H \in \mathbb{R}^{n \times n}$  astfel încât, pentru orice  $y \in \mathbb{R}^n$ :

$$f(x + y) = f(x) + \langle \nabla f(x), y \rangle + \frac{1}{2} \langle Hy, y \rangle + o(\|y\|^2)$$

- $H =: \nabla^2 f(x)$  este *matricea derivatelor de ordin II sau Hessiana* funcției  $f$  în  $x$
- Pe scurt: funcția este dublu diferențiabilă în  $x$  dacă admite o aproximare patratică de ordin II în vecinătatea lui  $x$ , i.e.  
 $g(y) := f(x) + \nabla f(x)^T y + \frac{1}{2} y^T H y$  astfel încât  $|f(x + y) - g(y)| = o(\|y\|^2)$



Funcții scalare:  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  se numește *dublu diferențială în punctul  $x$*  dacă există matricea simetrică  $H \in \mathbb{R}^{n \times n}$  astfel încât, pentru orice  $y \in \mathbb{R}^n$ :

$$f(x + y) = f(x) + \langle \nabla f(x), y \rangle + \frac{1}{2} \langle Hy, y \rangle + o(\|y\|^2)$$

- $H =: \nabla^2 f(x)$  este *matricea derivatelor de ordin II sau Hessiana* funcției  $f$  în  $x$
- Pe scurt: funcția este dublu diferențială în  $x$  dacă admite o aproximare patratică de ordin II în vecinătatea lui  $x$ , i.e.

$$g(y) := f(x) + \nabla f(x)^T y + \frac{1}{2} y^T H y \text{ astfel încât } |f(x + y) - g(y)| = o(\|y\|^2)$$

- $\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}$



Exemple:

- funcția pătratică:  $f(x) = \frac{1}{2}x^T Ax - b^T x$ , unde  $A \in \mathbb{R}^{n \times n}$ ,  $A = A^T$

$$\nabla^2 f(x) = A$$

$$\begin{aligned}f(x+y) &= \frac{1}{2}(x+y)^T A(x+y) - b^T(x+y) \\&= \frac{1}{2}x^T Ax - b^T x + (Ax - b)^T y + \frac{1}{2}y^T Ay \\&= f(x) + \nabla f(x)^T y + \frac{1}{2}y^T Ay,\end{aligned}$$

Observații:  $H = A$ .



## Definiție

Derivată a două a funcției (dublu diferențiabile)  $f$  este continuă Lipschitz cu constanta  $L$  dacă:

$$\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L\|x - y\| \quad \forall x, y.$$

Echivalent, se arată:

$$\|\nabla f(x) - \nabla f(y) - \nabla^2 f(y)(x - y)\| \leq \frac{L}{2}\|x - y\|^2 \quad \forall x, y$$

$$|f(x) - f(y) - \nabla f(y)^T(x - y) - \frac{1}{2}(x - y)^T \nabla^2 f(y)(x - y)| \leq \frac{L}{6}\|x - y\|^3 \quad \forall x, y$$

- $x^3$



## Definiție

Derivată a două a funcției (dublu diferențiabile)  $f$  este continuă Lipschitz cu constanta  $L$  dacă:

$$\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L\|x - y\| \quad \forall x, y.$$

Echivalent, se arată:

$$\|\nabla f(x) - \nabla f(y) - \nabla^2 f(y)(x - y)\| \leq \frac{L}{2}\|x - y\|^2 \quad \forall x, y$$

$$|f(x) - f(y) - \nabla f(y)^T(x - y) - \frac{1}{2}(x - y)^T \nabla^2 f(y)(x - y)| \leq \frac{L}{6}\|x - y\|^3 \quad \forall x, y$$

- $x^3$
- $\|x\|^3$




- O scurtă recapitulare
- Convexitate: Mulțimi convexe
- Diferențabilitate
- **Convexitate: Funcții convexe**



Funcția scalară  $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$  este convexă dacă:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \quad \forall \alpha \in [0, 1]$$



Functia scalară  $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$  este convexă dacă:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \quad \forall \alpha \in [0, 1]$$

$$f(x) := a^T x + b$$

$$\begin{aligned} f(\alpha x + (1 - \alpha)y) &= a^T[\alpha x + (1 - \alpha)y] + b \\ &= \alpha a^T x + (1 - \alpha)a^T y + b \\ &= \alpha(a^T x + b) + (1 - \alpha)(a^T y + b). \end{aligned}$$



Functia scalară  $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$  este convexă dacă:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \quad \forall \alpha \in [0, 1]$$

$$f(x) := |a^T x + b|$$


$$\begin{aligned} f(\alpha x + (1 - \alpha)y) &= |a^T[\alpha x + (1 - \alpha)y] + b| \\ &= |\alpha(a^T x + b) + (1 - \alpha)(a^T y + b)| \\ &\stackrel{I.T.}{\leq} |\alpha(a^T x + b)| + |(1 - \alpha)(a^T y + b)| \\ &= \alpha|a^T x + b| + (1 - \alpha)|a^T y + b|. \end{aligned}$$



## Funcții convexe diferențiabile

Funcția  $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$  diferențiabilă este convexă dacă:

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle \quad \forall x, y$$



Funcția  $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$  diferențiabilă este convexă dacă:

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle \quad \forall x, y$$

Dacă  $f$  este dublu diferențiabilă atunci definiția de mai sus este echivalentă cu:

$$\nabla^2 f(x) \succeq 0 \quad x \in \text{dom}(f)$$



Dacă  $f$  este dublu diferențiabilă atunci definiția de mai sus este echivalentă cu:

$$\nabla^2 f(x) \succeq 0 \quad x \in \text{dom}(f)$$

Exemplu:  $f : \mathbb{R} \rightarrow \mathbb{R}$ ,  $f(x) = x^4$

$$\nabla^2 f(x) = 12x^2 \geq 0 \quad \forall x \in \mathbb{R}.$$

$f : \mathbb{R}^2 \rightarrow \mathbb{R}$ ,  $f(x) = \|x\|^4$

$$\nabla f(x) = 4\|x\|^2 x$$

$$\nabla^2 f(x) = 4\|x\|I_2 + 8xx^T \succeq 0 \quad \forall x \in \mathbb{R}^2.$$



Fie  $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$  funcții convexe închise.

- *Suma:* pentru  $\alpha \in \mathbb{R}_+^m$ , funcția  $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$  este închisă și convexă



Fie  $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$  funcții convexe închise.

- *Suma:* pentru  $\alpha \in \mathbb{R}_+^m$ , funcția  $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$  este închisă și convexă
- *Maximum:* funcția  $f(x) = \max\{f_1(x), f_2(x), \dots, f_m(x)\}$  este închisă și convexă.



Fie  $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$  funcții convexe închise.

- *Suma:* pentru  $\alpha \in \mathbb{R}_+^m$ , funcția  $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$  este închisă și convexă
- *Maximum:* funcția  $f(x) = \max\{f_1(x), f_2(x), \dots, f_m(x)\}$  este închisă și convexă.
- *Componerea interioară cu un operator afin:* fie  $A \in \mathbb{R}^{p \times n}$ ,  $b \in \mathbb{R}^p$ , funcția  $g(x) = f(Ax - b)$  este închisă și convexă.



Fie  $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$  funcții convexe închise.

- *Suma:* pentru  $\alpha \in \mathbb{R}_+^m$ , funcția  $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$  este închisă și convexă
- *Maximum:* funcția  $f(x) = \max\{f_1(x), f_2(x), \dots, f_m(x)\}$  este închisă și convexă.
- *Compunerea interioară cu un operator afin:* fie  $A \in \mathbb{R}^{p \times n}$ ,  $b \in \mathbb{R}^p$ , funcția  $g(x) = f(Ax - b)$  este închisă și convexă.
- *Compunerea exterioară cu o funcție crescătoare:* fie  $\phi : \mathbb{R} \rightarrow \mathbb{R}$  o funcție crescătoare, funcția  $g(x) = \phi(f(x))$  este închisă și convexă.



## Operații care păstrează convexitatea - Exemple

Fie  $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$  funcții convexe închise.

- *Suma:* pentru  $\alpha \in \mathbb{R}_+^m$ , funcția  $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$  este închisă și convexă

$$\text{e.g. } \|Ax - b\|_2^2 + \|x\|_1$$



## Operații care păstrează convexitatea - Exemple

Fie  $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$  funcții convexe închise.

- *Suma:* pentru  $\alpha \in \mathbb{R}_+^m$ , funcția  $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$  este închisă și convexă

$$\text{e.g. } \|Ax - b\|_2^2 + \|x\|_1$$

- *Maximum:* funcția  $f(x) = \max\{f_1(x), f_2(x), \dots, f_m(x)\}$  este închisă și convexă.

$$\text{e.g. } |a^T x + b|, \|Ax + b\|_1$$



## Operații care păstrează convexitatea - Exemple

Fie  $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$  funcții convexe închise.

- *Suma:* pentru  $\alpha \in \mathbb{R}_+^m$ , funcția  $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$  este închisă și convexă

$$\text{e.g. } \|Ax - b\|_2^2 + \|x\|_1$$

- *Maximum:* funcția  $f(x) = \max\{f_1(x), f_2(x), \dots, f_m(x)\}$  este închisă și convexă.

$$\text{e.g. } |a^T x + b|, \|Ax + b\|_1$$

- *Componerea interioară cu un operator afin:* fie  $A \in \mathbb{R}^{p \times n}, b \in \mathbb{R}^p$ , funcția  $g(x) = f(Ax - b)$  este închisă și convexă.

$$\text{e.g. } \|Ax + b\|_p, p \geq 1$$



## Operații care păstrează convexitatea - Exemple

Fie  $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$  funcții convexe închise.

- *Suma:* pentru  $\alpha \in \mathbb{R}_+^m$ , funcția  $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$  este închisă și convexă

$$\text{e.g. } \|Ax - b\|_2^2 + \|x\|_1$$

- *Maximum:* funcția  $f(x) = \max\{f_1(x), f_2(x), \dots, f_m(x)\}$  este închisă și convexă.

$$\text{e.g. } |a^T x + b|, \|Ax + b\|_1$$

- *Componerea interioară cu un operator afin:* fie  $A \in \mathbb{R}^{p \times n}, b \in \mathbb{R}^p$ , funcția  $g(x) = f(Ax - b)$  este închisă și convexă.

$$\text{e.g. } \|Ax + b\|_p, p \geq 1$$

- *Componerea exterioară cu o funcție crescătoare:* fie  $\phi : \mathbb{R} \rightarrow \mathbb{R}$  o funcție crescătoare, funcția  $g(x) = \phi(f(x))$  este închisă și convexă.

$$\text{e.g. } \max\{0, (a^T x)^2 - b\}$$



# Notări

$\mathbb{R}^n$	spațiu real Euclidian $n$ -dimensional
$x_i$	componenta $i$ a vectorului $x \in \mathbb{R}^n$
$\mathbb{R}_+^n$	Cadrul $n$ -dimensional ne-negativ din $\mathbb{R}^n$ . $\mathbb{R}_+^n = \{x \in \mathbb{R}^n : x_i \geq 0\}$ .
$\langle \cdot, \cdot \rangle$	produsul scalar: $\langle x, y \rangle = x^T y = x_1 y_1 + \dots + x_n y_n$
$\nabla f(x), f'(x)$	gradientul/derivata funcției scalare $f(x)$
$\nabla^2 f(x), f''(x)$	matricea Hessiană a funcției scalare $f(x)$
$o(h(x))$	pentru $g : \mathbb{R}^n \rightarrow \mathbb{R}^m, h : \mathbb{R}^n \rightarrow \mathbb{R}^s$ , dacă $\frac{\ g(x)\ }{\ h(x)\ } \rightarrow 0$ când $\ x\  \rightarrow 0$ , atunci $g(x) = o(h(x))$
$\mathcal{O}(h(x))$	pentru $g : \mathbb{R}^n \rightarrow \mathbb{R}^m, h : \mathbb{R}^n \rightarrow \mathbb{R}^s$ , dacă există $\epsilon, \alpha > 0$ astfel încât $\ g(x)\  \leq \alpha \ h(x)\ $
$[x]_+$	pentru $\ x\  \leq \epsilon$ , atunci $g(x) = \mathcal{O}(h(x))$
$I_n$	max $\{0, x\}$
$A^T$	matricea identitate de ordin $n$
$\Lambda(A)$	matricea transpusă asociată matricii $A$
$\ A\ $	spectrul (multimea valorilor proprii) matricii simetrice $A$
$A \succeq 0$	norma matricii $A \in \mathbb{R}^{n \times n}$ : $\ A\  = \max_{\ x\ =1} \ Ax\  = \max_{1 \leq i \leq n}  \lambda_i(A) $
$A \succeq B$	matricea simetrică $A$ este pozitiv semidefinită: $x^T Ax \geq 0$ pentru $\forall x \in \mathbb{R}^n$ . Echivalent $\Lambda(A) \subset \mathbb{R}_+^n$ .
	matricile $A, B$ sunt simetrice și $A - B \succeq 0$



- B. Polyak, Introduction to Optimization, Optimization Software Inc., New York, 1987
- D. Bertsekas, Nonlinear Programming, Third Edition. Athena Scientific, 2016.
- Y. Nesterov, Introductory Lectures on Convex Optimization, Kluwer, 2004.
- Hiriart-Urruty, Jean-Baptiste, and Claude Lemaréchal. *Convex analysis and minimization algorithms I: Fundamentals*. Vol. 305. Springer science & business media, 1996.