

# TEHNICI DE OPTIMIZARE

## Curs 2

Andrei Pătrașcu

Departament Informatică  
Universitatea din București

- **Modele de optimizare continuă fără constrângeri. Condiții de extrem**
- Existență și unicitate. Mulțimi izo(sub-)nivel. Convexitate tare
- Metoda Gradient



$$(MfC) : \min_x f(x)$$

Aspecte în formularea și rezolvarea (OfC):

- definiția (verificarea) unei soluții
- existența unei soluții
- unicitatea soluției
- calculul unei soluții (algorithm iterativ)





## Definiție (Minim local/global)

Punctul  $x^*$  se numește **minim local** dacă: există  $\epsilon > 0$  astfel încât

$$f(x^*) \leq f(x) \quad \forall x \in \{x : \|x - x^*\| \leq \epsilon\}$$

Mai mult, dacă  $f(x^*) \leq f(x), \forall x \in \text{dom}(f)$ , atunci  $x^*$  este **minim global**.



### Teoremă (Fermat)

*Presupunem funcția  $f$  diferențiabilă. Fie  $x^*$  un punct de minim al  $f(\cdot)$  din  $\mathbb{R}^n$ , atunci:*

$$\nabla f(x^*) = 0.$$



## Teoremă (Fermat)

*Presupunem funcția  $f$  diferențiabilă. Fie  $x^*$  un punct de minim al  $f(\cdot)$  din  $\mathbb{R}^n$ , atunci:*

$$\nabla f(x^*) = 0.$$

**Demonstrație:** Presupunem  $\nabla f(x^*) \neq 0$ . Atunci:

$$\begin{aligned} f(x^* - \tau \nabla f(x^*)) &= f(x^*) - \tau \|\nabla f(x^*)\|^2 + o(\tau \|\nabla f(x^*)\|) \\ &= f(x^*) - \tau \left( \|\nabla f(x^*)\|^2 + \frac{1}{\tau} o(\tau) \right) < f(x^*), \end{aligned}$$

pentru  $\tau > 0$  suficient de mic, prin definiția lui  $o(\tau)$ . Ultima inegalitate intră în contradicție cu presupunerea că  $x^*$  este punct de minim.



### Teoremă (Fermat)

*Presupunem funcția  $f$  diferențiabilă. Fie  $x^*$  un punct de minim al  $f(\cdot)$  din  $\mathbb{R}^n$ , atunci:*

$$\nabla f(x^*) = 0.$$

Observăm că demonstrația teoremei de mai sus oferă o perspectivă asupra calculării unei direcții de descreștere a funcției  $f$ .

### Idee

Dacă  $\nabla f(x) \neq 0$  (i.e.  $x$  nu este punct de extrem), atunci  $x - \tau \nabla f(x)$  asigură descreșterea funcției  $f$ , pentru pasul  $\tau$  suficient de mic.



Minimizare pătratică:

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} x^T P x + q^T x + r$$

- Problema este rezolvată prin setul de ecuații:  $Px^* + q = 0$
- $P \succ 0$ , atunci avem soluție unică  $x^* = -P^{-1}q$ ;
- dacă  $Px^* + q = 0$  nu are soluție atunci  $f$  este nemărginită inferior.





Problema aproximării liniare:

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2$$

$A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$  sunt datele problemei.

- Există cel puțin o soluție  $\nabla f(x^*) := A^T(Ax^* - b) = 0$
- Dacă  $b \in \text{Im}(A)$  atunci  $Ax^* = b$  (interpolare)
- Dacă  $b \notin \text{Im}(A)$  atunci  $A^T Ax^* = A^T b$  (aproximare).



## Exemple

Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$



Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$

$$\text{Puncte critice: } \nabla f(x^*) = \begin{bmatrix} x_1^* \\ (x_2^*)^3 - x_2^* \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$



## Exemple

Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$


$$\text{Puncte critice: } \nabla f(x^*) = \begin{bmatrix} x_1^* \\ (x_2^*)^3 - x_2^* \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$x_{(1)}^* = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad x_{(2)}^* = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad x_{(3)}^* = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$



## Teoremă

*Presupunem funcția  $f$  convexă și diferențiabilă în  $x^*$ . Dacă  $\nabla f(x^*) = 0$  atunci  $x^*$  este minim global al funcției  $f$ .*



### Teoremă


*Presupunem funcția  $f$  convexă și diferențiabilă în  $x^*$ . Dacă  $\nabla f(x^*) = 0$  atunci  $x^*$  este minim global al funcției  $f$ .*


**Demonstrație:** Din definiția funcțiilor convexe avem:

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle = f(x^*).$$



Condiția  $\nabla f(z) = 0$  este satisfăcută de orice punct staționar:





- $a$ : punct de minim (local)
- $b$ : punct șa (inflexiune)
- $c$ : punct de maxim (local)





Derivata de ordin I nu oferă informații despre natura punctului staționar! Este necesar să apelăm la derivate de ordin superior.

### Teoremă

*Presupunem funcția  $f$  este dublu diferențiabilă. Fie  $x^*$  un punct de minim al  $f(\cdot)$  din  $\mathbb{R}^n$ , atunci:*

$$\nabla^2 f(x^*) \succeq 0.$$



**Demonstrație:** Știm că  $\nabla f(x^*) = 0$ , atunci deducem pentru orice  $d \in \mathbb{R}^n$  și  $\tau > 0$  suficient de mic:

$$f(x^*) \leq f(x^* + \tau d) = f(x^*) + \frac{\tau^2}{2} \langle \nabla^2 f(x^*) d, d \rangle + o(\tau^2)$$
$$\langle \nabla^2 f(x^*) d, d \rangle \geq \frac{o(\tau^2)}{\tau^2}.$$

Luând  $\tau \rightarrow 0$  atunci partea dreaptă se anulează și obținem  $\nabla^2 f(x^*) \succeq 0$ .



### Teoremă

*Presupunem funcția  $f$  este dublu diferențiabilă. Dacă  $\nabla f(x^*) = 0$  și:*

$$\nabla^2 f(x^*) \succ 0$$

*atunci  $x^*$  este minim local.*



### Teoremă

*Presupunem funcția  $f$  este dublu diferențiabilă. Dacă  $\nabla f(x^*) = 0$  și:*

$$\nabla^2 f(x^*) \succ 0$$

*atunci  $x^*$  este minim local.*

**Demonstrație:** Pentru orice  $d \in \mathbb{R}^n$  și  $\tau > 0$  suficient de mic:

$$\begin{aligned} f(x^* + \tau d) &= f(x^*) + \frac{\tau^2}{2} \langle \nabla^2 f(x^*) d, d \rangle + o(\tau^2 \|d\|^2) \\ &\geq f(x^*) + \frac{\tau^2}{2} \lambda_{\min} \|d\|^2 + o(\tau^2 \|d\|^2) \\ &= f(x^*) + \tau^2 \|d\|^2 \left( \frac{\lambda_{\min}}{2} + \frac{o(\tau^2 \|d\|^2)}{\tau^2 \|d\|^2} \right), \end{aligned}$$

unde  $\lambda_{\min}$  reprezintă valoarea proprie minimă a matricii  $\nabla^2 f(x^*)$ . Pentru  $\tau$  suficient de mic avem  $\frac{\lambda_{\min}}{2} + \frac{o(\tau^2 \|d\|^2)}{\tau^2 \|d\|^2} \geq 0$ .




### Observație

Sub condițiile necesare de ordin I și II ( $\nabla f(x^*) = 0, \nabla^2 f(x^*) \succeq 0$ ), dacă cele suficiente nu au loc (matricea  $\nabla^2 f(x^*)$  nu este pozitiv definită) atunci  $x^*$  nu este neapărat minim local.

**Exemplu:** Fie  $f(x) = x^3$ , atunci  $x^* = 0$  satisface condițiile necesare, însă:

$$f''(x^*) = 0,$$

$x^* = 0$  este punct șa.



Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$



Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$

$$\text{Puncte critice: } \nabla f(x^*) = \begin{bmatrix} x_1^* \\ (x_2^*)^3 - x_2^* \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$



Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$

$$\text{Puncte critice: } \nabla f(x^*) = \begin{bmatrix} x_1^* \\ (x_2^*)^3 - x_2^* \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$x_{(1)}^* = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad x_{(2)}^* = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad x_{(3)}^* = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$





Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$

$$\text{Puncte critice: } \nabla f(x^*) = \begin{bmatrix} x_1^* \\ (x_2^*)^3 - x_2^* \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\nabla^2 f(x) = \begin{bmatrix} 1 & 0 \\ 0 & 3x_2^2 - 1 \end{bmatrix}$$



Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$

$$\text{Puncte critice: } \nabla f(x^*) = \begin{bmatrix} x_1^* \\ (x_2^*)^3 - x_2^* \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\nabla^2 f(x_{(1)}^*) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad \nabla^2 f(x_{(2)}^*) = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \quad \nabla^2 f(x_{(3)}^*) = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$$



Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$

$$\text{Puncte critice: } \nabla f(x^*) = \begin{bmatrix} x_1^* \\ (x_2^*)^3 - x_2^* \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\nabla^2 f(x_{(1)}^*) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \quad \nabla^2 f(x_{(2)}^*) = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \quad \nabla^2 f(x_{(3)}^*) = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$$

punct staționar

min. local nesingular

min. local nesingular



- În cazurile liniar-pătratice, condițiile de optimalitate ajută direct la determinarea unei soluții



- În cazurile liniar-pătratice, condițiile de optimalitate ajută direct la determinarea unei soluții
- În general, rezolvarea condițiilor de optimalitate (determinarea unui punct care satisface relațiile de egalitate/inegalitate) are, adesea, aceeași dificultate ca și problema originală



- În cazurile liniar-pătratice, condițiile de optimalitate ajută direct la determinarea unei soluții
- În general, rezolvarea condițiilor de optimalitate (determinarea unui punct care satisface relațiile de egalitate/inegalitate) are, adesea, aceeași dificultate ca și problema originală
- Care este utilitatea acestora în aceste cazuri neliniare?
  - Condițiile de optimalitate reflectă proprietăți ale punctelor de extrem
  - Aduc intuiție asupra construcției de algoritmi iterativi pentru rezolvarea problemei originale




- Modele de optimizare continuă fără constrângeri. Condiții de extrem
- **Existență și unicitate. Mulțimi izo(sub-)nivel. Convexitate tare**
- Metoda Gradient



## Teoremă (Weierstrass)

*Fie funcția  $f$  continuă și mulțimile sub-nivel  $S_f(\alpha) = \{x : f(x) \leq \alpha\}$  nevide și mărginite. Atunci există un punct de minim global al funcției  $f$ .*

Condiția mărginirii pare esențială: e.g.  $f(x) = x$ ,  $f(x) = \frac{1}{1+x^2}$





## Teoremă (Weierstrass)

*Fie funcția  $f$  continuă și mulțimile sub-nivel  $S_f(\alpha) = \{x : f(x) \leq \alpha\}$  nevide și mărginite. Atunci există un punct de minim global al funcției  $f$ .*

Cu toate acestea, dacă  $f(x) = \|Ax - b\|_2^2$  atunci:

- $f$  atinge minim-ul pe  $\mathbb{R}^n$
- $S_f(\alpha)$  **nu este necesar mărginită!**



## Definiție



*Un punct de optim este **local unic** dacă într-o vecinătate a acestuia nu mai există alte puncte de optim.*



## Definiție

Un punct de optim este **local unic** dacă într-o vecinătate a acestuia nu mai există alte puncte de optim.

E.g.  $\min\{2, |x|\}$ ,  $\frac{1}{\frac{1}{2} + e^{10(x-2)}} - \frac{1}{\frac{1}{2} + e^{10(x+2)}}$



## Definiție

Un punct de optim este **local unic** dacă într-o vecinătate a acestuia nu mai există alte puncte de optim.

## Definiție

Un punct de minim  $x^*$  este **nesingular** dacă:  $\nabla f(x^*) = 0, \nabla^2 f(x^*) \succ 0$ .



## Definiție

Un punct de optim este **local unic** dacă într-o vecinătate a acestuia nu mai există alte puncte de optim.

## Definiție

Un punct de minim  $x^*$  este **nesingular** dacă:  $\nabla f(x^*) = 0, \nabla^2 f(x^*) \succ 0$ .

## Teoremă (Unicitate)

Un punct de minim  $x^*$  nesingular este local unic.



## Exemplu

Fie funcția  $f(x) = f(x_1, x_2) := \frac{1}{2}x_1^2 + \frac{1}{4}x_2^4 - \frac{1}{2}x_2^2$

$$\text{Puncte critice: } \nabla f(x^*) = \begin{bmatrix} x_1^* \\ (x_2^*)^3 - x_2^* \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$x_{(1)}^* = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad x_{(2)}^* = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad x_{(3)}^* = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

$$\nabla^2 f(x) = \begin{bmatrix} 1 & 0 \\ 0 & 3x_2^2 - 1 \end{bmatrix}$$

$$\nabla^2 f(x_{(1)}^*) = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

$$\nabla^2 f(x_{(2)}^*) = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$$

$$\nabla^2 f(x_{(3)}^*) = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$$

punct staționar

min. local nesingular

min. local nesingular



### Definiție

*Mulțimile subnivel și izonivel ale funcției  $f$  de parametru  $\alpha > 0$  sunt:*

$$S_f(\alpha) := \{x \in \text{dom } f : f(x) \leq \alpha\}$$

$$S_f^\circ(\alpha) := \{x \in \text{dom } f : f(x) = \alpha\}.$$

- $S_f^\circ(\alpha)$  reprezintă frontiera mulțimii  $S_f(\alpha)$
- Observăm  $S_f(\alpha) \subseteq S_f(\beta)$  pentru  $\alpha \leq \beta$ .
- Pentru funcțiile  $f$  convexe,  $S_f(\alpha)$  sunt convexe.
- Nu sunt întodeauna mărginite.





## Definiție

*Mulțimile subnivel și izonivel ale funcției  $f$  de parametru  $\alpha > 0$  sunt:*

$$S_f(\alpha) := \{x \in \text{dom } f : f(x) \leq \alpha\}$$

$$S_f^\circ(\alpha) := \{x \in \text{dom } f : f(x) = \alpha\}.$$






## Definiție

*Mulțimile subnivel și izonivel ale funcției  $f$  de parametru  $\alpha > 0$  sunt:*

$$S_f(\alpha) := \{x \in \text{dom } f : f(x) \leq \alpha\}$$

$$S_f^\circ(\alpha) := \{x \in \text{dom } f : f(x) = \alpha\}.$$



### Remarcă

*Dacă  $f$  este convexă, atunci  $S_f(\alpha)$  este convexă pentru oricare  $\alpha \geq f^*$ .*

- $\{x \in \mathbb{R}^n : \|Ax - b\|_2 \leq 1\}$
- $\{(x, t) \in \mathbb{R}^{n+1} : \|x\|_2 \leq t\}$
- $\{x \in \mathbb{R}_+^n : \sum_i x_i \ln x_i \leq 1\}$



Denumim *lățimea* unei mulțimi convexe  $C \subseteq \mathbb{R}^n$  pe direcția  $v$  ( $\|v\| = 1$ ):

$$W(C, v) = \sup_{z \in C} v^T z - \inf_{z \in C} v^T z.$$



Denumim *lățimea* unei mulțimi convexe  $C \subseteq \mathbb{R}^n$  pe direcția  $v$  ( $\|v\| = 1$ ):

$$W(C, v) = \sup_{z \in C} v^T z - \inf_{z \in C} v^T z.$$

Lățimea maximă și minimă a lui  $C$  sunt date de:

$$W_{\max}(C) = \sup_{\|v\|=1} W(C, v) \quad W_{\min}(C) = \inf_{\|v\|=1} W(C, v).$$



Denumim *lățimea* unei mulțimi convexe  $C \subseteq \mathbb{R}^n$  pe direcția  $v$  ( $\|v\| = 1$ ):

$$W(C, v) = \sup_{z \in C} v^T z - \inf_{z \in C} v^T z.$$

Lățimea maximă și minimă a lui  $C$  sunt date de:

$$W_{\max}(C) = \sup_{\|v\|=1} W(C, v) \quad W_{\min}(C) = \inf_{\|v\|=1} W(C, v).$$

Numărul de condiționare al mulțimii  $C$ :

$$\kappa(C) = \frac{W_{\max}(C)^2}{W_{\min}(C)^2},$$

redă o măsură a excentricității mulțimii  $C$ .



Fie  $E = \{v : (x - c)P^{-1}(x - c) \leq 1\}$ ,  $P \succ 0$ , atunci lățimea mulțimii  $E$  în direcția  $v$  este

$$\begin{aligned}\sup_{z \in E} v^T z - \inf_{z \in E} v^T z &= (\|P^{1/2}v\| + v^T c) - (-\|P^{1/2}v\| + v^T c) \\ &= 2\|P^{1/2}v\|.\end{aligned}$$


Atunci

$$W_{\max}(E) = 2\lambda_{\max}(P)^{1/2} \quad W_{\min}(E) = 2\lambda_{\min}(P)^{1/2}.$$

și

$$\kappa(E) = \frac{\lambda_{\max}(P)}{\lambda_{\min}(P)}.$$

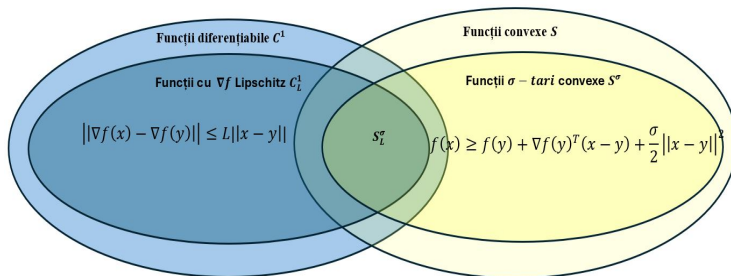




- Funcții diferențiabile ( $\nabla f$  Lipschitz); e.g.  $D, X \rightarrow \|DX - Y\|_F^2$
- Funcții convexe diferențiabile ( $\nabla f$  Lipschitz); e.g.  $X \rightarrow \|AX - Y\|_F^2$
- Funcții convexe nediferențiabile; e.g.  $X \rightarrow \|AX - Y\|_1$

Există clase mai "puternice"?







Reamintim definițiile (echivalente) ale funcțiilor convexe  $S$ :

- Ordin 0:  $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$ ,  $\forall \alpha \in [0, 1], x, y$



Reamintim definițiile (echivalente) ale funcțiilor convexe  $S$ :

- Ordin 0:  $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$ ,  $\forall \alpha \in [0, 1], x, y$
- Ordin 1:  $f(x) \geq f(y) + \nabla f(y)^T(x - y)$ ,  $\forall x, y$



Reamintim definițiile (echivalente) ale funcțiilor convexe  $S$ :

- Ordin 0:  $f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$ ,  $\forall \alpha \in [0, 1], x, y$
- Ordin 1:  $f(x) \geq f(y) + \nabla f(y)^T(x - y)$ ,  $\forall x, y$
- Ordin 2:  $\nabla^2 f(x) \succeq 0 \quad \forall x$



## Definiție

O funcție  $f \in S^\sigma$  este  $\sigma$ -tare convexă dacă satisface:

- **Ordin 0:**  
$$f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y) - \alpha(1-\alpha)\frac{\sigma}{2}\|x-y\|^2, \quad \forall \alpha \in [0, 1], x, y$$
- **Ordin 1:**  $f(x) \geq f(y) + \nabla f(y)^T(x-y) + \frac{\sigma}{2}\|x-y\|^2, \quad \forall x, y$
- **Ordin 2:**  $\nabla^2 f(x) \succeq \sigma I_n \quad \forall x$

Exemple:

- $x \rightarrow (c^T x)^2 + \frac{1}{2}\|x\|_2^2$
- $x \rightarrow \|Ax - b\|_2^2 + \|x\|_2^2$
- $x \rightarrow \frac{1}{2}x^T Hx + q^T x, \quad H \succ 0$



Considerăm  $y = x^*$  (punct de optim):

$$\begin{aligned} f(x) &\geq f(x^*) + \nabla f(x^*)^T (x - x^*) + \frac{\sigma}{2} \|x - x^*\|^2, \quad \forall x \\ &= f^* + \frac{\sigma}{2} \|x - x^*\|^2, \quad \forall x. \end{aligned}$$

Funcția  $f \in \mathcal{S}^\sigma$  are *creștere pătratică*:

$$f(x) - f^* \geq \frac{\sigma}{2} \|x - x^*\|^2.$$



Dacă  $f \in \mathcal{S}_L^\sigma$  atunci:

$$\frac{L}{2} \|x - x^*\|^2 \geq f(x) - f^* \geq \frac{\sigma}{2} \|x - x^*\|^2, \quad \forall x.$$



$$H_1 = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}$$

$$H_2 = \begin{bmatrix} 4 & 0 \\ 0 & 10^{-4} \end{bmatrix}$$



- Modele de optimizare continuă fără constrângeri. Condiții de extrem
- Existență și unicitate. Mulțimi izo(sub-)nivel. Convexitate tare
- **Metoda Gradient**



Definim generic un algoritm iterativ: inițializăm  $x^0 \in \mathbb{R}^n$  și iterăm

$$x^{k+1} = T(x^k, x^{k-1}, \dots, x^0)$$

până când criteriul de oprire ales este satisfăcut.

- un algoritm iterativ de optimizare primește informații precum: punctul de inițializare  $x^0$ , funcția obiectiv  $f$  (și alte informații legate de  $f$ ), acuratețea  $\epsilon$  dorită, etc.





Definim generic un algoritm iterativ: inițializăm  $x^0 \in \mathbb{R}^n$  și iterăm

$$x^{k+1} = T(x^k, x^{k-1}, \dots, x^0)$$

până când criteriul de oprire ales este satisfăcut.

- un algoritm iterativ de optimizare primește informații precum: punctul de inițializare  $x^0$ , funcția obiectiv  $f$  (și alte informații legate de  $f$ ), acuratețea  $\epsilon$  dorită, etc.
- datele se folosesc pentru a executa iterația  $T$ , care definește un set de operații asupra întregului istoric  $\{x^0, \dots, x^k\}$ .



Definim generic un algoritm iterativ: inițializăm  $x^0 \in \mathbb{R}^n$  și iterăm

$$x^{k+1} = T(x^k, x^{k-1}, \dots, x^0)$$

până când criteriul de oprire ales este satisfăcut.

- un algoritm iterativ de optimizare primește informații precum: punctul de inițializare  $x^0$ , funcția obiectiv  $f$  (și alte informații legate de  $f$ ), acuratețea  $\epsilon$  dorită, etc.
- datele se folosesc pentru a executa iterația  $T$ , care definește un set de operații asupra întregului istoric  $\{x^0, \dots, x^k\}$ .
- deoarece nu se va executa un număr infinit de iterații, orice algoritm iterativ va răspunde la întrebarea: "Când poate fi considerat  $x^k$  o aproximare suficient de precisă a unui punct de optim?"



---

**Algorithm 1:** Algoritm de ordin I ( $x^0, \epsilon, \dots$ ):

---

**Data:**  $k := 0$


```
1 while criteriu oprire = fals do  
2   |   Calculează:  $d^k \in \text{span}\{\nabla f(x^k), \nabla f(x^{k-1}), \dots, \nabla f(x^0)\}$   
3   |   Actualizează  $x^{k+1}$  pe baza  $d^k$  și  $\{x^k, x^{k-1}, \dots, x^0\}$   
4   |    $k := k + 1$   
5 end
```

---




Majoritatea algoritmilor de ordin I realizează un model aproximativ local (pătratic) al funcției obiectiv  $\mathcal{A}(x; x^k, \dots, x^0; f)$ . Aplicarea lui  $T$  reprezintă este echivalentă cu determinarea soluției optime a acestuia, i.e

$$\min_x \mathcal{A}(x; x^k, \dots, x^0; f).$$



Majoritatea algoritmilor de ordin I realizează un model aproximativ local (pătratic) al funcției obiectiv  $\mathcal{A}(x; x^k, \dots, x^0; f)$ . Aplicarea lui  $T$  reprezintă este echivalentă cu determinarea soluției optime a acestuia, i.e

$$\min_x \mathcal{A}(x; x^k, \dots, x^0; f).$$



$$\min_{x \in \mathbb{R}^n} f(x)$$

Dacă  $f$  este diferențiabilă și  $\nabla f(x) \neq 0$ . Atunci:

$$\begin{aligned} f(x - \tau \nabla f(x)) &= f(x) - \tau \|\nabla f(x)\|^2 + o(\tau \|\nabla f(x)\|) \\ &= f(x) - \tau \left( \|\nabla f(x)\|^2 + \frac{1}{\tau} o(\tau) \right) < f(x), \end{aligned}$$

pentru  $\tau > 0$  suficient de mic, prin definiția lui  $o(\tau)$ . Ultima inegalitate intră în contradicție cu presupunerea că  $x^*$  este punct de minim.



## Aproximarea pătratică în $x^k$

$$f(x) \approx \mathcal{A}(x; x^k; f) := f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T H_k (x - x^k)$$

Alegerea matricii Hessiane  $H_k$  determină calitatea aproximării!

Pentru alegerea  $H_k = \alpha_k I_n$  ( $\alpha_k > 0$ ), modelul se simplifică :

$$f(x) \approx \mathcal{A}(x; x^k; f) := f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2\alpha_k} \|x - x^k\|^2$$




Figure:  $f(x) = \ln(1 + e^{-2x+1}) + \ln(1 + e^{2x+1})$ ;  $x^0 = \frac{1}{2}$ ,  $\alpha_0 = 1/4$



Considerăm:

$$x^{k+1} = \arg \min_x f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2\alpha_k} \|x - x^k\|^2$$

Din condițiile de ordin I avem:

$$\nabla f(x^k) + \frac{1}{\alpha_k} (x^{k+1} - x^k) = 0$$

$$\frac{1}{\alpha_k} (x^{k+1} - x^k) = -\nabla f(x^k)$$

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k)$$





Intuim următorul algoritm: inițializăm  $x^0$

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k)$$

unde  $\alpha_k \geq 0$  se numește **lungimea pasului** iterației.

**Metoda Gradient** a fost introdusă în 1847 de către Auguste Cauchy pentru rezolvarea unui sistem neliniar cu 6 necunoscute:

A. Cauchy, *Méthode générale pour la résolution des systèmes d'équations simultanées*. C.R. Acad. Sci. Paris, 25: 536-538, 1847.



---

**Algorithm 2:** Metoda Gradient ( $x^0, \epsilon, \{\alpha_k\}_{k \geq 0}$ ):

---

**Data:**  $k := 0$

```
1 while criteriu oprire = fals do  
2   |   Calculează:  $\nabla f(x^k)$   
3   |    $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$   
4   |    $k := k + 1$   
5 end
```

---

- pas constant:  $\alpha_k = \alpha$
- cea mai abruptă pantă:  $\alpha_k = \arg \min_{\alpha} f(x^k - \alpha \nabla f(x^k))$
- adaptiv



Evaluarea calității unei iterații se poate realiza în mai multe moduri (pe baza acurateții  $\epsilon > 0$ ):

- $\|x^k - x^*\| \leq \epsilon \Leftrightarrow x^k \in B(x^*; \epsilon)$



Evaluarea calității unei iterații se poate realiza în mai multe moduri (pe baza acurateții  $\epsilon > 0$ ):

- $\|x^k - x^*\| \leq \epsilon \Leftrightarrow x^k \in B(x^*; \epsilon)$
- $f(x^k) - f^* \leq \epsilon \Leftrightarrow x^k \in S_f(f^* + \epsilon)$



Evaluarea calității unei iterații se poate realiza în mai multe moduri (pe baza acurateții  $\epsilon > 0$ ):

- $\|x^k - x^*\| \leq \epsilon \Leftrightarrow x^k \in B(x^*; \epsilon)$
- $f(x^k) - f^* \leq \epsilon \Leftrightarrow x^k \in S_f(f^* + \epsilon)$
- $\|\nabla f(x)\| \leq \epsilon$



## Teoremă (Polyak)

*Fie  $f$  diferențiabilă pe  $\mathbb{R}^n$  cu gradientul  $\nabla f$  continuu Lipschitz:*

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|.$$

*De asemenea, presupunem  $\min_x f(x) > -\infty$  și  $0 < \alpha < \frac{1}{2L}$ . Atunci șirul generat de Metoda Gradient  $x^{k+1} = x^k - \alpha \nabla f(x^k)$  satisface:*

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$

$$\text{și } f(x^{k+1}) \leq f(x^k).$$



**Demonstrație pe scurt:** Pentru simplitate  $\alpha_k = \frac{1}{L}$ . Din continuitatea Lipschitz avem

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) + \nabla f(x^k)^T (x^{k+1} - x^k) + \frac{L}{2} \|x^{k+1} - x^k\|^2 \\ &\leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2. \end{aligned}$$

Este evidentă descreșterea  $f(x^{k+1}) \leq f(x^k)$ . Trecând termenul normei în partea stângă avem:

$$\begin{aligned} \frac{1}{2L} \|\nabla f(x^k)\|^2 &\leq f(x^k) - f(x^{k+1}) \quad \forall k \geq 0 \\ \frac{1}{2L} \sum_{i=0}^{k-1} \|\nabla f(x^i)\|^2 &\leq \sum_{i=0}^{k-1} f(x^i) - f(x^{i+1}) = f(x^0) - f(x^{k+1}) \\ &\leq f(x^0) - f^*. \end{aligned}$$

Prin trecerea la limită  $k \rightarrow \infty$  obținem rezultatul.



**Teorema** (Polyak). Fie  $f$  diferențiabilă pe  $\mathbb{R}^n$  cu gradientul  $\nabla f$  continuu Lipschitz:  $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$ . De asemenea, presupunem  $\min_x f(x) > -\infty$  și  $0 < \alpha < \frac{1}{2L}$ . Atunci șirul generat de Metoda Gradient  $x^{k+1} = x^k - \alpha \nabla f(x^k)$  satisface:

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$

și  $f(x^{k+1}) \leq f(x^k)$ .

- Nu este necesară convexitatea (în acest caz, MG converge la un punct staționar)





**Teorema** (Polyak). Fie  $f$  diferențiabilă pe  $\mathbb{R}^n$  cu gradientul  $\nabla f$  continuu Lipschitz:  $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$ . De asemenea, presupunem  $\min_x f(x) > -\infty$  și  $0 < \alpha < \frac{1}{2L}$ . Atunci șirul generat de Metoda Gradient  $x^{k+1} = x^k - \alpha \nabla f(x^k)$  satisface:

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$

și  $f(x^{k+1}) \leq f(x^k)$ .

- Nu este necesară convexitatea (în acest caz, MG converge la un punct staționar)
- Este necesară continuitatea Lipschitz și o aproximare a constantei  $L$



**Teorema** (Polyak). Fie  $f$  diferențiabilă pe  $\mathbb{R}^n$  cu gradientul  $\nabla f$  continuu Lipschitz:  $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$ . De asemenea, presupunem  $\min_x f(x) > -\infty$  și  $0 < \alpha < \frac{1}{2L}$ . Atunci șirul generat de Metoda Gradient  $x^{k+1} = x^k - \alpha \nabla f(x^k)$  satisface:

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$

și  $f(x^{k+1}) \leq f(x^k)$ .

- Nu este necesară convexitatea (în acest caz, MG converge la un punct staționar)
- Este necesară continuitatea Lipschitz și o aproximare a constantei  $L$
- Fără o alegere limitată a pasului, MG poate diverge (exemplu!)



**Teorema** (Polyak). Fie  $f$  diferențiabilă pe  $\mathbb{R}^n$  cu gradientul  $\nabla f$  continuu Lipschitz:  $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$ . De asemenea, presupunem  $\min_x f(x) > -\infty$  și  $0 < \alpha < \frac{1}{2L}$ . Atunci șirul generat de Metoda Gradient  $x^{k+1} = x^k - \alpha \nabla f(x^k)$  satisface:

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$

și  $f(x^{k+1}) \leq f(x^k)$ .

- Nu este necesară convexitatea (în acest caz, MG converge la un punct staționar)
- Este necesară continuitatea Lipschitz și o aproximare a constantei  $L$
- Fără o alegere limitată a pasului, MG poate diverge (exemplu!)
- Când pasul este variabil, inegalitatea descreșterii devine:

$$f(x^{k+1}) \leq f(x^k) - \alpha_k \left(1 - \frac{L\alpha_k}{2}\right) \|\nabla f(x^k)\|^2.$$



**Teorema** (Polyak). Fie  $f$  diferențiabilă pe  $\mathbb{R}^n$  cu gradientul  $\nabla f$  continuu Lipschitz:  $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$ . De asemenea, presupunem  $\min_X f(x) > -\infty$  și  $0 < \alpha < \frac{1}{2L}$ . Atunci șirul generat de Metoda Gradient  $x^{k+1} = x^k - \alpha \nabla f(x^k)$  satisface:

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$

și  $f(x^{k+1}) \leq f(x^k)$ .

- În cazul  $S_f(f(x^0))$  mărginită, avem în plus convergența unui subșir al  $x^k$  la un punct staționar al lui  $f$  (contrar,  $f(x) = \frac{1}{1+\|x\|^2}$ )



**Teorema** (Polyak). Fie  $f$  diferențiabilă pe  $\mathbb{R}^n$  cu gradientul  $\nabla f$  continuu Lipschitz:  $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$ . De asemenea, presupunem  $\min_X f(x) > -\infty$  și  $0 < \alpha < \frac{1}{2L}$ . Atunci șirul generat de Metoda Gradient  $x^{k+1} = x^k - \alpha \nabla f(x^k)$  satisface:

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$

și  $f(x^{k+1}) \leq f(x^k)$ .

- În cazul  $S_f(f(x^0))$  mărginită, avem în plus convergența unui subșir al  $x^k$  la un punct staționar al lui  $f$  (contrar,  $f(x) = \frac{1}{1+\|x\|^2}$ )
- Garanții de convergență către un minim local/global nu există!



**Teorema** (Polyak). Fie  $f$  diferențiabilă pe  $\mathbb{R}^n$  cu gradientul  $\nabla f$  continuu Lipschitz:  $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$ . De asemenea, presupunem  $\min_x f(x) > -\infty$  și  $0 < \alpha < \frac{1}{2L}$ . Atunci șirul generat de Metoda Gradient  $x^{k+1} = x^k - \alpha \nabla f(x^k)$  satisface:

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$


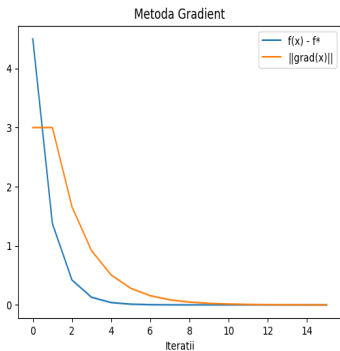
și  $f(x^{k+1}) \leq f(x^k)$ .

- În cazul  $S_f(f(x^0))$  mărginită, avem în plus convergența unui subșir al  $x^k$  la un punct staționar al lui  $f$  (contrar,  $f(x) = \frac{1}{1+\|x\|^2}$ )
- Garanții de convergență către un minim local/global nu există!
- Rata de convergență MG, în general, poate fi foarte pesimistă, e.g. pentru  $f(x) = \frac{1}{x}$ , cu  $x \geq 1$ , MG devine  $x^{k+1} = x^k + \frac{1}{(x^k)^2}$ , care implică  $|f'(x^k)| = O(1/k^{2/3})$ .



$$\min_{x \in \mathbb{R}^2} \frac{1}{2} x^T A x - b^T x$$

$$A = \begin{bmatrix} 1 & 0 \\ 0 & -2 \end{bmatrix}, \quad b = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$$



### Teoremă (Rată de convergență (convexitate))

*Fie  $f$  convexă cu gradientul  $\nabla f$  continuu Lipschitz:*

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|.$$

*De asemenea, presupunem  $\min_x f(x) > -\infty$  și  $0 < \alpha < \frac{1}{2L}$ . Atunci șirul generat de Metoda Gradient  $x^{k+1} = x^k - \alpha \nabla f(x^k)$  satisface:*

$$f(x^k) - f^* \leq \frac{L\|x^0 - x^*\|^2}{2k} \quad \forall k \geq 0.$$





**Demonstrație pe scurt:** Pentru simplitate  $\alpha_k = \frac{1}{L}$ . Din continuitatea Lipschitz avem

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) + \nabla f(x^k)^T (x^{k+1} - x^k) + \frac{L}{2} \|x^{k+1} - x^k\|^2 \\ &\leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2. \end{aligned}$$

Este evidentă descreșterea  $f(x^{k+1}) \leq f(x^k)$ . Folosim următoarele observații:

- (i)  $x^k = x^0 - \sum_{i=1}^{k-1} \nabla f(x^i)$
- (ii)  $\frac{1}{2} \|\sum_i a^i\|^2 = \frac{1}{2} \sum_i \|a^i\|^2 + \sum_i (a^i)^T \left( \sum_{j=0}^{i-1} (a^j)^T \right)$
- (iii)  $\max_z z^T a - \frac{\alpha}{2} \|z\|^2 = \frac{1}{2\alpha} \|a\|^2$



**Demonstrație pe scurt:** din continuitatea Lipschitz avem pentru  $k \geq 0$

$$\begin{aligned} f(x^{k+1}) &\leq f(x^k) + \nabla f(x^k)^T (x^{k+1} - x^k) + \frac{L}{2} \|x^{k+1} - x^k\|^2 \\ &\leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2 \\ &\leq f(x^*) + \nabla f(x^k)^T (x^k - x^*) - \frac{1}{2L} \|\nabla f(x^k)\|^2 \\ &\stackrel{(i)}{=} f(x^*) + \nabla f(x^k)^T (x^0 - x^*) - \frac{1}{L} \nabla f(x^k)^T \left( \sum_{j=0}^{k-1} \nabla f(x^j) \right) - \frac{1}{2L} \|\nabla f(x^k)\|^2. \end{aligned}$$

Însumăm inegalitățile cu indecșii  $i = 0, \dots, k$ .





- Rolul ratei de convergență: determinarea complexității rezolvării (OfC) până la o precizie fixată, e.g.

$$f(x^k) - f^* \leq \mathcal{O}((C/k)) < \epsilon \Rightarrow$$

$$\text{dupa } k \geq \mathcal{O}\left(\frac{C}{\epsilon}\right) \text{ atingem } f(x) - f^* \leq \epsilon.$$



- Rolul ratei de convergență: determinarea complexității rezolvării (OfC) până la o precizie fixată, e.g.

$$f(x^k) - f^* \leq \mathcal{O}((C/k)) < \epsilon \Rightarrow$$


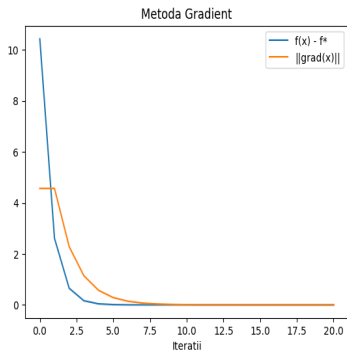
$$\text{dupa } k \geq \mathcal{O}\left(\frac{C}{\epsilon}\right) \text{ atingem } f(x) - f^* \leq \epsilon.$$

- Clase de rate de convergență:
  - subliniară: e.g  $\mathcal{O}(C/k)$
  - liniară: e.g  $\mathcal{O}\left(C \cdot \left(\frac{1}{2}\right)^k\right)$
  - superliniară: e.g  $\mathcal{O}\left(C \cdot \left(\frac{1}{2}\right)^{k^2}\right)$
  - pătratică: e.g  $\mathcal{O}\left(C \cdot \left(\frac{1}{2}\right)^{2^k}\right)$



$$\min_{x \in \mathbb{R}^2} \frac{1}{2} \|Ax - b\|_2^2$$


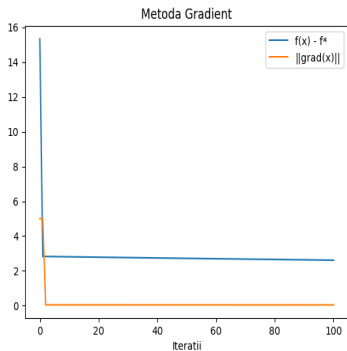
$$A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$



# Convergență sub convexitate

$$\min_{x \in \mathbb{R}^2} \frac{1}{2} \|Ax - b\|_2^2$$

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 0.02 \end{bmatrix}$$



- B. Polyak, Introduction to Optimization, Optimization Software Inc., New York, 1987
- D. Bertsekas, Nonlinear Programming, Third Edition. Athena Scientific, 2016.
- Y. Nesterov, Introductory Lectures on Convex Optimization, Kluwer, 2004.
- Hiriart-Urruty, Jean-Baptiste, and Claude Lemaréchal. *Convex analysis and minimization algorithms I: Fundamentals*. Vol. 305. Springer science & business media, 1996.
- [www.desmos.com](http://www.desmos.com)

