

TEHNICI DE OPTIMIZARE

Curs 5

Andrei Pătrașcu

Departament Informatică
Universitatea din București

- **Probleme de minimizare cu constrângeri (POC). Condiții de optimalitate.**
- Algoritmi de ordinul I pentru POC
- Convergență
- Exemple și aplicații



$$(POC) : \min_{x \in \mathbb{R}^n} f(x) \text{ supus la } x \in Q$$

- Q mulțime fezabilă (convexă, închisă)



$$(POC) : \min_{x \in \mathbb{R}^n} f(x) \text{ supus la } x \in Q$$

- Q mulțime fezabilă (convexă, închisă)
- se urmărește determinarea lui $x^* \in Q$ care asigură:

$$f(x^*) \leq f(x), \quad \forall x \in Q, \|x - x^*\| \leq \epsilon \text{ (minim local)}$$

$$f(x^*) \leq f(x), \quad \forall x \in Q \text{ (minim global)}$$



$$(POC) : \min_{x \in \mathbb{R}^n} f(x) \text{ supus la } x \in Q$$

- Q mulțime fezabilă (convexă, închisă)
- se urmărește determinarea lui $x^* \in Q$ care asigură:

$$f(x^*) \leq f(x), \quad \forall x \in Q, \|x - x^*\| \leq \epsilon \text{ (minim local)}$$

$$f(x^*) \leq f(x), \quad \forall x \in Q \text{ (minim global)}$$

- echivalent: $\min_x f(x) + I_Q(x)$, unde $I_Q(x) = \begin{cases} 0 & x \in Q \\ \infty & x \notin Q \end{cases}$



- LP: $\min_x c^T x$ s.l. $Ax = b, x \geq 0$



Exemple

- LP: $\min_x c^T x$ s.l. $Ax = b, x \geq 0$
- QP: $\min_x \frac{1}{2} x^T H x - q^T x$ s.l. $Ax \leq b, Gx = h$



Exemple

- LP: $\min_x c^T x$ s.l. $Ax = b, x \geq 0$
- QP: $\min_x \frac{1}{2} x^T H x - q^T x$ s.l. $Ax \leq b, Gx = h$
- SOCP: $\min_x c^T x$ s.l. $\|A_i x - b_i\| \leq \beta_i, Gx = h \quad i = 1, \dots, m$



- LP: $\min_x c^T x$ s.l. $Ax = b, x \geq 0$
- QP: $\min_x \frac{1}{2}x^T Hx - q^T x$ s.l. $Ax \leq b, Gx = h$
- SOCP: $\min_x c^T x$ s.l. $\|A_i x - b_i\| \leq \beta_i, Gx = h \ i = 1, \dots, m$
- QCQP: $\min_x \frac{1}{2}x^T Hx - q^T x$ s.l. $\|A_i x - b_i\| \leq \beta_i, Gx = h \ i = 1, \dots, m$



- LP: $\min_x c^T x$ s.l. $Ax = b, x \geq 0$
- QP: $\min_x \frac{1}{2}x^T Hx - q^T x$ s.l. $Ax \leq b, Gx = h$
- SOCP: $\min_x c^T x$ s.l. $\|A_i x - b_i\| \leq \beta_i, Gx = h \ i = 1, \dots, m$
- QCQP: $\min_x \frac{1}{2}x^T Hx - q^T x$ s.l. $\|A_i x - b_i\| \leq \beta_i, Gx = h \ i = 1, \dots, m$
- SDP: $\min_x c^T x$ s.l. $x_1 F_1 + \dots + x_n F_n + G \preceq 0, Gx = h$




Numim mulțimea fezabilă simplă dacă următoarele obiecte pot fi calculate eficient:

- punct fezabil: $x \in Q$
- proiecția ortogonală: $\pi_Q(y) := \operatorname{argmin}_x \|x - y\|$ s.l. $x \in Q$
- oracol liniar: $\phi_Q(y) := \operatorname{argmin}_x x^T y$ s.l. $x \in Q$
- mulțimi active
- ...




Constrângeri simple

• $\min_x x^2$ s.l. $1 \leq x \leq 2$




Constrângeri simple

• $\min_x x^2$ s.l. $1 \leq x \leq 2$



• $\min_x x \log(x)$ s.l. $\ell \leq x \leq u$



- $\min_x x_1^2 + x_2^2$ s.l. $1 \leq x_1 \leq 2, 1 \leq x_2 \leq 2$ (separabilitate)



- $\min_x x_1^2 + x_2^2$ s.l. $1 \leq x_1 \leq 2, 1 \leq x_2 \leq 2$ (separabilitate)
- $\min_x x_1^2 + x_2^2$ s.l. $x \geq 0, x_1 + x_2 = 1$ (proiecție)




O problemă particulară

Problema proiecției ortogonale Euclidiene:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|x - y\|_2^2 \\ \text{s.t.} \quad & x \in Q \end{aligned}$$

Soluția $\pi_Q(y)$: punctul cel mai apropiat de y , care aparține mulțimii fezabile Q



Problema proiecției ortogonale Euclidiene:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|x - y\|_2^2 \\ \text{s.l. } & x \in Q \end{aligned}$$

Soluția $\pi_Q(y)$: punctul cel mai apropiat de y , care aparține mulțimii fezabile Q

- Dacă Q este închisă atunci $\pi_Q(\cdot)$ există
- $y \in Q \rightarrow \pi_Q(y) = y$
- Condiții de optimalitate: $(y - \pi_Q(y))^T (x - \pi_Q(y)) \leq 0 \quad \forall x \in Q.$



- bila $Q := B(0, r) = \{x \in \mathbb{R}^n : \|x\| \leq r\} \Rightarrow \pi_Q(y) = \left\{1, \frac{r}{\|y\|}\right\} y$



- bila $Q := B(0, r) = \{x \in \mathbb{R}^n : \|x\| \leq r\} \Rightarrow \pi_Q(y) = \left\{1, \frac{r}{\|y\|}\right\} y$
- hiperparalelipiped
 $Q := [l, u]^n = \{x \in \mathbb{R}^n : x \in [l, u]\} \Rightarrow \pi_Q(y)_i = \max\{l_i, \min\{u_i, y_i\}\}$



- bila $Q := B(0, r) = \{x \in \mathbb{R}^n : \|x\| \leq r\} \Rightarrow \pi_Q(y) = \left\{1, \frac{r}{\|y\|}\right\} y$
- hiperparalelipiped
 $Q := [l, u]^n = \{x \in \mathbb{R}^n : x \in [l, u]\} \Rightarrow \pi_Q(y)_i = \max\{l_i, \min\{u_i, y_i\}\}$
- hiperplan $Q := H(a, b) = \{x \in \mathbb{R}^n : a^T x = b\} \Rightarrow \pi_Q(y) = y - \frac{a^T y - b}{\|a\|_2^2} a$



- bila $Q := B(0, r) = \{x \in \mathbb{R}^n : \|x\| \leq r\} \Rightarrow \pi_Q(y) = \left\{1, \frac{r}{\|y\|}\right\} y$
- hiperparalelipiped
 $Q := [l, u]^n = \{x \in \mathbb{R}^n : x \in [l, u]\} \Rightarrow \pi_Q(y)_i = \max\{l_i, \min\{u_i, y_i\}\}$
- hiperplan $Q := H(a, b) = \{x \in \mathbb{R}^n : a^T x = b\} \Rightarrow \pi_Q(y) = y - \frac{a^T y - b}{\|a\|_2^2} a$
- semispațiu
 $Q := S(a, b) = \{x \in \mathbb{R}^n : a^T x \leq b\} \Rightarrow \pi_Q(y) = y - \frac{\max\{0, a^T y - b\}}{\|a\|_2^2} a$



- $Q = Q_1 \times Q_2 \Rightarrow \pi_Q(x) = \begin{bmatrix} \pi_{Q_1}(x_1) \\ \pi_{Q_2}(x_2) \end{bmatrix}$



- $Q = Q_1 \times Q_2 \Rightarrow \pi_Q(x) = \begin{bmatrix} \pi_{Q_1}(x_1) \\ \pi_{Q_2}(x_2) \end{bmatrix}$
- $Q = Q_1 \times Q_2 \times \cdots \times Q_n \Rightarrow \pi_Q(x) = \begin{bmatrix} \pi_{Q_1}(x_1) \\ \vdots \\ \pi_{Q_n}(x_n) \end{bmatrix}$



- $Q = Q_1 \times Q_2 \Rightarrow \pi_Q(x) = \begin{bmatrix} \pi_{Q_1}(x_1) \\ \pi_{Q_2}(x_2) \end{bmatrix}$
- $Q = Q_1 \times Q_2 \times \cdots \times Q_n \Rightarrow \pi_Q(x) = \begin{bmatrix} \pi_{Q_1}(x_1) \\ \vdots \\ \pi_{Q_n}(x_n) \end{bmatrix}$
- $Q = Q_1 \cap Q_2 \cap \cdots \cap Q_n \Rightarrow \pi_Q(x) = ?$



$$(POC) : \quad \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Reformulare (nediferențiabilă):

$$(POC) : \quad \min_{x \in \mathbb{R}^n} f(x) + \iota_Q(x) = \begin{cases} f(x) & x \in Q \\ \infty & x \notin Q. \end{cases}$$

Condiții de optimalitate?



Reformulare Th. Fermat ($Q = \mathbb{R}^n$):

$$x^* = \arg \min_x f(x^*) + \nabla f(x^*)^T (x - x^*) + \frac{1}{2\alpha} \|x - x^*\|^2$$

$$x^* = x^* - \alpha \nabla f(x^*)$$

$$0 = \nabla f(x^*).$$



Reformulare Th. Fermat ($Q = \mathbb{R}^n$):

$$x^* = \arg \min_x f(x^*) + \nabla f(x^*)^T (x - x^*) + \frac{1}{2\alpha} \|x - x^*\|^2$$

$$x^* = x^* - \alpha \nabla f(x^*)$$

$$0 = \nabla f(x^*).$$

Intuiție în caz constrâns ($Q \subseteq \mathbb{R}^n$):

$$x^* = \arg \min_{x \in Q} f(x^*) + \nabla f(x^*)^T (x - x^*) + \frac{1}{2\alpha} \|x - x^*\|^2$$

$$x^* = \pi_Q(x^* - \alpha \nabla f(x^*))$$

$$0 = x^* - \pi_Q(x^* - \alpha \nabla f(x^*)).$$



$$(POC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Dacă $Q = \mathbb{R}^n$ atunci în toate punctele staționare $\nabla f(x^*) = 0$.

Definiție

Fie f diferențiabilă, $x \in Q$ și $\alpha > 0$ atunci denumim **operator de gradient redus peste mulțimea Q** transformarea:

$$\mathcal{G}_Q(x; \alpha) = \frac{1}{\alpha} [x - \pi_Q(x - \alpha \nabla f(x))]$$

Dacă $Q = \mathbb{R}^n$ atunci $\mathcal{G}_Q(x; \alpha) = \nabla f(x)$.



Definiție

Fie f diferențiabilă, $x \in Q$ și $\alpha > 0$ atunci denumim **operator de gradient redus peste mulțimea Q** transformarea:

$$\mathcal{G}_Q(x; \alpha) = \frac{1}{\alpha} [x - \pi_Q(x - \alpha \nabla f(x))]$$

- $f(x) = \frac{1}{2} \|x - y\|^2$

$$\mathcal{G}(x; 1) = x - \pi_Q(x - (x - y)) = x - \pi_Q(y) = x - x^*$$



Definiție

Fie f diferentiabilă, $x \in Q$ și $\alpha > 0$ atunci denumim **operator de gradient redus peste mulțimea Q** transformarea:

$$\mathcal{G}_Q(x; \alpha) = \frac{1}{\alpha} [x - \pi_Q(x - \alpha \nabla f(x))]$$

- $f(x) = \frac{1}{2} \|x - y\|^2$

$$\mathcal{G}(x; 1) = x - \pi_Q(x - (x - y)) = x - \pi_Q(y) = x - x^*$$

- $f(x) = \frac{1}{2} \|Ax - b\|^2, Q = B(0; 1)$

$$\begin{aligned} \mathcal{G}(x; 1) &= x - \pi_Q(x - A^T(Ax - b)) = x - \pi_Q((I - A^T A)x + A^T b) \\ &= x - \frac{1}{\|(I - A^T A)x + A^T b\|} [(I - A^T A)x + A^T b] \\ &= (1 - \bar{\alpha})x + \bar{\alpha} \nabla f(x). \end{aligned}$$



$$(OPC) : \quad \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Pp. $x \in Q, \mathcal{G}(x) \neq 0$ atunci din definiția lui \mathcal{G} avem:

$$\begin{aligned} \alpha^2 \|\mathcal{G}(x; \alpha) - \nabla f(x)\|_2^2 &= \|\pi_Q(x - \alpha \nabla f(x)) - (x - \alpha \nabla f(x))\|_2^2 \\ &= \min_{z \in Q} \|z - (x - \alpha \nabla f(x))\|_2^2 \\ &\leq \|x - (x - \alpha \nabla f(x))\|_2^2 = \alpha^2 \|\nabla f(x)\|_2^2. \end{aligned}$$

Desfășurând norma rezultă:

$$\frac{1}{2} \|\mathcal{G}(x; \alpha)\|_2^2 \leq \nabla f(x)^T \mathcal{G}(x; \alpha).$$



$$(OPC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Dacă f diferențiabilă atunci:

$$\begin{aligned} f(x - \alpha \mathcal{G}(x; \alpha)) &= f(x) - \alpha \nabla f(x)^T \mathcal{G}(x; \alpha) + o(-\alpha \mathcal{G}(x; \alpha)) \\ &\leq f(x) - \alpha \frac{1}{2} \|\mathcal{G}(x; \alpha)\|_2^2 + o(-\alpha \mathcal{G}(x; \alpha)) \\ &\leq f(x) - \alpha \|\mathcal{G}(x; \alpha)\|_2 \left[\frac{1}{2} \|\mathcal{G}(x; \alpha)\|_2 - \frac{o(-\alpha \mathcal{G}(x; \alpha))}{\alpha \|\mathcal{G}(x; \alpha)\|_2} \right]. \end{aligned}$$

Un pas α suficient de mic asigură: $f(x - \alpha \mathcal{G}(x; \alpha)) < f(x)$, de aceea orice minim x^* satisface $\mathcal{G}(x^*; \alpha) = 0$.



$$(OPC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Teoremă

Fie f diferențiabilă, Q mulțime convexă închisă și α o constantă pozitivă. Orice minim x^ al problemei OPC satisface:*

$$x^* = \pi_Q(x^* - \alpha \nabla f(x^*)) \Leftrightarrow \mathcal{G}(x^*; \alpha) = 0$$

Mai mult, dacă f convexă atunci x^ soluția OPC dacă și numai dacă $\mathcal{G}(x^*; \alpha) = 0$.*

- Analog condițiilor de ordin I pentru cazul neconstrâns (i.e. $Q = \mathbb{R}^n$)



$$(OPC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Teoremă

Fie f diferențiabilă, Q mulțime convexă închisă și α o constantă pozitivă. Orice minim x^ al problemei OPC satisface:*

$$x^* = \pi_Q(x^* - \alpha \nabla f(x^*)) \Leftrightarrow \mathcal{G}(x^*; \alpha) = 0$$

Mai mult, dacă f convexă atunci x^ soluția OPC dacă și numai dacă $\mathcal{G}(x^*; \alpha) = 0$.*

- Analog condițiilor de ordin I pentru cazul neconstrâns (i.e. $Q = \mathbb{R}^n$)
- Condiții necesare în general, dar nec. și suficiente în cazul f convexă



$$(OPC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Teoremă

Fie f diferențiabilă, Q mulțime convexă închisă și α o constantă pozitivă. Orice minim x^ al problemei OPC satisface:*

$$x^* = \pi_Q(x^* - \alpha \nabla f(x^*)) \Leftrightarrow \mathcal{G}(x^*; \alpha) = 0$$

Mai mult, dacă f convexă atunci x^ soluția OPC dacă și numai dacă $\mathcal{G}(x^*; \alpha) = 0$.*

- Analog condițiilor de ordin I pentru cazul neconstrâns (i.e. $Q = \mathbb{R}^n$)
- Condiții necesare în general, dar nec. și suficiente în cazul f convexă
- Cand π_Q este tractabil, condiția de mai sus este verificabilă!



$$\max_x \|Ax\|_2^2 \text{ s.t. } \|x\| \leq 1$$



$$\max_x \|Ax\|_2^2 \text{ s.t. } \|x\| \leq 1$$

$$x^* = \pi_Q(x^* - \nabla f(x^*)) = \pi_Q(x^* - A^T Ax^*)$$

$$x^* = \frac{1}{\|(I - A^T A)x^*\|} (I - A^T A)x^*$$

$$x^* = \frac{1}{1 - \|(I - A^T A)x^*\|} A^T Ax^* = \lambda^* A^T Ax^*.$$



$$\max_x \|Ax\|_2^2 \text{ s.t. } \|x\| \leq 1$$

$$x^* = \pi_Q(x^* - \nabla f(x^*)) = \pi_Q(x^* - A^T Ax^*)$$

$$x^* = \frac{1}{\|(I - A^T A)x^*\|} (I - A^T A)x^*$$

$$x^* = \frac{1}{1 - \|(I - A^T A)x^*\|} A^T Ax^* = \lambda^* A^T Ax^*.$$

Puncte staționare: vectorii proprii asociați $A^T A$.

Soluție: vectorul propriu x^* asociat $\lambda_{\max}(A^T A)$.




Condiția de ordin I:

$$x^* = \pi_Q(x^* - \alpha \nabla f(x^*)) \Leftrightarrow \mathcal{G}(x^*; \alpha) = 0$$

este echivalentă cu:

$$\nabla f(x^*)^T (x - x^*) \geq 0, \quad \forall x \in Q.$$

Interpretare: *Direcția $-\nabla f(x^*)$ face un unghi obtuz cu direcțiile fezabile*



Exemplu curs 1:

$$\begin{aligned} \min \quad & f(x) := (x_1 + x_2)^2 \\ \text{s.t.} \quad & 0 \leq x_1 \leq 1 \\ & 0 \leq x_2 \leq 1 \end{aligned}$$



Exemplu curs 1:

$$\begin{aligned} \min \quad & f(x) := (x_1 + x_2)^2 \\ \text{s.t.} \quad & 0 \leq x_1 \leq 1 \\ & 0 \leq x_2 \leq 1 \end{aligned}$$

$$\begin{aligned} x^* &= \pi_{[0,1]^2}(x^* - \nabla f(x^*)) \\ \begin{bmatrix} x_1^* \\ x_2^* \end{bmatrix} &= \begin{bmatrix} \pi_{[0,1]}(-x_2^*) \\ \pi_{[0,1]}(-x_1^*) \end{bmatrix} \\ x^* &= 0. \end{aligned}$$



$$\begin{aligned} \min_{x \in \mathbb{R}^3} \quad & f(x) = x_1^2 + x_2^2 + x_3^2 + (x_1 + 2x_2 - 4)^2 \\ \text{s.t.} \quad & \|x\| \leq 1. \end{aligned}$$

Care sunt condițiile de optimalitate de ordin I?



$$\begin{array}{ll}\min & f(x) := c^T x \\ \text{s.t.} & x \in [l, u].\end{array}$$

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & x \in [l, u].\end{array}$$

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & Ax = b.\end{array}$$



- Probleme de minimizare cu constrângeri (POC). Condiții de optimalitate.
- **Algoritmi de ordinul I pentru POC. Convergență**
- Exemple și aplicații



Din relațiile de mai sus, pentru α suficient de mic obținem descreșterea:

$$f(x - \alpha \mathcal{G}(x)) < f(x)$$


care sugerează iterația $x^+ = x - \alpha \mathcal{G}(x)$.

Calcularea operatorului $\mathcal{G}(\cdot)$ folosește $\pi_Q(\cdot)$, care este tractabil doar în anumite cazuri particulare "simple": bilă, hiperplan, hiperplan etc.



Metoda Gradientului Proiectat: inițial $x^0 \in Q$

$$x^{k+1} := x^k - \alpha \mathcal{G}(x^k) = \pi_Q(x^k - \alpha \nabla f(x^k))$$




[Polyak, pg. 234]



Interpretare:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_z f(x^k) + \nabla f(x^k)^T(z - x^k) + \frac{1}{2\alpha_k} \|z - x^k\|^2 \\ &= \operatorname{argmin}_z \frac{1}{2} \|z - (x^k - \alpha_k \nabla f(x^k))\|^2 \quad (\text{exercitiu!}) \end{aligned}$$



[Polyak, pg. 234]



Algorithm 1: Metoda Gradientului Proiectat (MGP)

$(x^0, \epsilon, \{\alpha_k\}_{k \geq 0})$:

Data: $k := 0$

```

1 while criteriu oprire = fals do
2   |   Calculează:  $\nabla f(x^k)$ 
3   |    $x^{k+1} = \pi_Q(x^k - \alpha_k \nabla f(x^k))$ 
4   |    $k := k + 1$ 
5 end
    
```


Teoremă

Fie f o funcție diferențiabilă cu gradient Lipschitz și Q mulțimea fezabilă convexă. Pentru pasul $\alpha_k = \alpha \in (0, 2/L)$, șirul MGP satisface:

$$\|\mathcal{G}(x^k)\| \rightarrow 0 \text{ când } k \rightarrow \infty.$$

Mai mult, dacă f convexă și X^ mulțimea optimă POC, atunci $x^k \rightarrow x^* \in X^*$.*

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|^2 \quad \text{s.t.} \quad l \leq x \leq u.$$



$$\begin{aligned} \min_{x \in \mathbb{R}^3} \quad & f(x) = x_1^2 + x_2^2 + x_3^2 + (x_1 + 2x_2 - 4)^2 \\ \text{s.l.} \quad & \|x\| \leq 1. \end{aligned}$$

Calculați prima iterație a MGP cu pas constant $\alpha = 1/L$, pornind din $x^0 = [0 \ 0 \ 0]$.



Teoremă (Nesterov, 2014)

Fie f o funcție diferențiabilă cu gradient Lipschitz cu constanta L , tare-convexă cu constanta σ , iar Q convexă și închisă. Pentru pasul $\alpha \in \left(0, \frac{2}{L+\sigma}\right]$ avem:

$$\|x^k - x^*\| \leq \left(1 - \frac{\sigma}{L}\right)^k \|x^0 - x^*\|$$

- Performanță similară cu cea a MG
- $x^k \in S_f(f^* + \epsilon)$ după $\mathcal{O}(\kappa \log(1/\epsilon))$ iterații



Ipoteza: Este posibilă calcularea eficientă a operatorului cost liniar:

$$\phi_Q(y) := \operatorname{argmin}_{z \in Q} y^T z$$




Ipoteza: Este posibilă calcularea eficientă a operatorului cost liniar:

$$\phi_Q(y) := \operatorname{argmin}_{z \in Q} y^T z$$

Metoda Gradientului Condițional realizează un model aproximativ liniar al costului și folosește soluția acestuia la fiecare iterație k :

$$\begin{aligned}\phi_Q(x^k) &:= \operatorname{argmin}_{z \in Q} \nabla f(x^k)^T z \\ x^{k+1} &= x^k + \alpha_k(\phi_Q(x^k) - x^k).\end{aligned}$$





Algorithm 2: Metoda Gradientului Condițional (MGC)

$(x^0, \epsilon, \{\alpha_k\}_{k \geq 0})$:

Data: $k := 0$

```
1 while criteriu oprire = fals do  
2   Calculează:  $\phi_Q(x^k) := \operatorname{argmin}_{z \in Q} \nabla f(x^k)^T z$   
3    $x^{k+1} = x^k + \alpha_k(\phi_Q(x^k) - x^k)$   
4    $k := k + 1$   
5 end
```

Teoremă

Fie f o funcție diferențiabilă cu gradient Lipschitz și Q mulțimea fezabilă convexă. Pentru pasul $\alpha_k = \operatorname{argmin}_{\alpha \in [0,1]} f(x^k + \alpha(\phi_Q(x^k) - x^k))$, șirul MGC satisface:

$$\nabla f(x^k)^T (x^k - \phi_Q(x^k)) \rightarrow 0 \text{ când } k \rightarrow \infty.$$

Mai mult, dacă f convexă atunci $f(x^k) - f^* = \mathcal{O}(1/k)$.

$$\begin{aligned} \min_{x \in \mathbb{R}^3} \quad & f(x) = x_1^2 + x_2^2 + x_3^2 + (x_1 + 2x_2 - 4)^2 \\ \text{s.l.} \quad & \|x\| \leq 1. \end{aligned}$$

Calculați prima iterație a MGC cu pas constant $\alpha = 1/L$, pornind din $x^0 = [0 \ 0 \ 0]$.



Calculați soluția următoarelor probleme:

- $\arg \min_{x \in \mathbb{R}^n} c^T x$ s.l. $l \leq x \leq u$
- $\arg \min_{x \in \mathbb{R}^n} c^T x$ s.l. $\|x\| \leq r$
- $\arg \min_{x \in \mathbb{R}^n} c^T x$ s.l. $\frac{1}{2}x^T Hx - q^T x \leq \beta$ ($\beta > 0, H \succ 0$)



Metoda Gradientului Accelerat (Nesterov): fie $x^0 \in \mathbb{R}^n$, $y^0 = x^0$, $\beta = \frac{1 - \sqrt{\kappa_f}}{1 + \sqrt{\kappa_f}}$

$$1 \quad x^k = \pi_Q \left(y^k - \frac{1}{L} \nabla f(y^k) \right)$$

$$2 \quad y^{k+1} = x^{k+1} + \beta(x^{k+1} - x^k)$$

• **Accelerare:** $\mathcal{O}(\sqrt{\kappa_f} \log(1/\epsilon))$ vs $\mathcal{O}(\kappa_f \log(1/\epsilon))$ (MG)



Metoda Gradientului Accelerat (Nesterov): fie $x^0 \in \mathbb{R}^n$, $y^0 = x^0$, $\beta = \frac{1 - \sqrt{\kappa_f}}{1 + \sqrt{\kappa_f}}$

$$1 \quad x^k = \pi_Q \left(y^k - \frac{1}{L} \nabla f(y^k) \right)$$

$$2 \quad y^{k+1} = x^{k+1} + \beta(x^{k+1} - x^k)$$

- **Accelerare:** $\mathcal{O}(\sqrt{\kappa_f} \log(1/\epsilon))$ vs $\mathcal{O}(\kappa_f \log(1/\epsilon))$ (MG)
- Iterația MGA are același ordin de complexitate per iterație ca MG



Metoda Gradientului Accelerat (Nesterov): fie $x^0 \in \mathbb{R}^n$, $y^0 = x^0$, $\beta = \frac{1 - \sqrt{\kappa_f}}{1 + \sqrt{\kappa_f}}$

$$1 \quad x^k = \pi_Q \left(y^k - \frac{1}{L} \nabla f(y^k) \right)$$

$$2 \quad y^{k+1} = x^{k+1} + \beta(x^{k+1} - x^k)$$

- **Accelerare:** $\mathcal{O}(\sqrt{\kappa_f} \log(1/\epsilon))$ vs $\mathcal{O}(\kappa_f \log(1/\epsilon))$ (MG)
- Iterația MGA are același ordin de complexitate per iterație ca MG
- MGA este mai puțin robustă la erori



- Metoda Newton Proiectat
- Metoda Gradientilor Conjugați (cu proiecție)
- Metode Direcții Descrescere

