

# TEHNICI DE OPTIMIZARE

## Curs 6

Andrei Pătrașcu

Departament Informatică  
Universitatea din București

Metoda Newton (pentru constrângeri simple)

$$x^{k+1} = \operatorname{argmin}_{z \in Q} f(x^k) + \nabla f(x^k)^T(z - x^k) + \frac{1}{2\alpha_k}(z - x^k)^T \nabla^2 f(x^k)(z - x^k).$$



## Metoda Newton (cu proiecție)

$$x^{k+1} = \operatorname{argmin}_{z \in Q} f(x^k) + \nabla f(x^k)^T (z - x^k) + \frac{1}{2\alpha_k} (z - x^k)^T \nabla^2 f(x^k) (z - x^k).$$

La iterația  $k$ , necesită rezolvarea:

$$QP : \min_{z \in Q} q^T z + \frac{1}{2\alpha_k} z^T H z.$$



- Constrângeri de egalitate.
- Condiții de optimalitate



Fie seria de timp  $\{y_t\}_{t=1}^n \in \mathbb{R}^n$ , presupunem descompunerea:


$$y_t = x_t + \epsilon_t,$$

- $x_t$  reprezintă componenta-trend de variație lentă
- $\epsilon_t$  componenta zgomot de variație rapidă

*Filtrare a trend-ului* = estimarea componentei "netede"  $x_t$ .



## Serii de timp: Filtrare trend



$$\min_x \frac{1}{2} \sum_{t=1}^n (x_t - y_t)^2 + \rho \sum_{t=2}^{n-1} (x_{t-1} - 2x_t + x_{t+1})^2. \quad (1)$$

- Funcția obiectiv urmărește reducerea reziduuului  $\{y_t - x_t\}$  și, în același timp, ajustarea "netezimii" lui  $x_t$ .
- Diferența de ordin 2:  $x_{t-1} - 2x_t + x_{t+1}$  este nulă dacă și numai dacă  $\{x_{t-1}, x_t, x_{t+1}\}$  sunt coliniare.



În forma restrânsă:

$$x_{HP}^* := \operatorname{argmin}_x \frac{1}{2} \|x - y\|_2^2 + \rho \|Dx\|_2^2, \quad \text{unde } D \in \mathbb{R}^{(n-2) \times n}$$

$$D = \begin{bmatrix} 1 & -2 & 1 & & & & \\ & 1 & -2 & 1 & & & \\ & & \vdots & \vdots & \vdots & & \\ & & & 1 & -2 & 1 & \\ & & & & 1 & -2 & 1 \end{bmatrix}$$

$$\begin{aligned} x_{HP}^* &:= \operatorname{argmin}_x \frac{1}{2} \|x - y\|_2^2 + \rho \|z\|_2^2 \\ \text{s.t. } Dx &= z. \end{aligned}$$











$$x_{\ell_1}^* := \operatorname{argmin}_x \frac{1}{2} \|x - y\|_2^2 + \rho \|Dx\|_1$$

- $\|\cdot\|_2^2$  devine  $\|\cdot\|_1$
- Dacă  $D = I_n$  atunci problema este separabilă:  
$$x_t^* = \operatorname{argmin}_{x_t \in \mathbb{R}} \frac{1}{2} (x_t - y_t)^2 + \lambda |x_t|$$





# Reducție dimensională



$$X = \begin{bmatrix} 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \end{bmatrix}$$

- Fiecare  $X_i$  se poate recupera complet din baza  $b$  și codul  $z_i$ .



$$X = \begin{bmatrix} 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \end{bmatrix}$$

- Fiecare  $X_i$  se poate recupera complet din baza  $b$  și codul  $z_i$ .
- Dimensiunea lui  $X$  ( 72 octeți) poate fi redusă la  $\text{size}(b) + \text{size}(z) = 9 \cdot 4 = \mathbf{36}$  octeți.



$$X = \begin{bmatrix} 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \end{bmatrix}$$

- Fiecare  $X_i$  se poate recupera complet din baza  $b$  și codul  $z_i$ .
- Dimensiunea lui  $X$  ( 72 octeți) poate fi redusă la  $\text{size}(b) + \text{size}(z) = 9 \cdot 4 = \mathbf{36}$  octeți.
- Dacă numărul de coloane  $m$  crește (coliniar pe  $b$ ), atunci dimensiunea lui  $z$  crește proporțional  $\mathbf{4m}$  octeți (dimensiunea bazei este constantă).



$$X = \begin{bmatrix} 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \end{bmatrix}$$

- Fiecare  $X_i$  se poate recupera complet din baza  $b$  și codul  $z_i$ .
- Dimensiunea lui  $X$  ( 72 octeți) poate fi redusă la  $\text{size}(b) + \text{size}(z) = 9 \cdot 4 = \mathbf{36}$  octeți.
- Dacă numărul de coloane  $m$  crește (coliniar pe  $b$ ), atunci dimensiunea lui  $z$  crește proporțional  $\mathbf{4m}$  octeți (dimensiunea bazei este constantă).
- În particular, fixând  $b = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$  avem reconstrucție perfectă  $X_i = z_i b$  unde

$$z_1 = 15, z_2 = 0.1, z_3 = 0.5, z_4 = -100, z_5 = -1.01, z_6 = 0.00001$$



Matricea de covarianță:

$$S = XX^T$$

Calculul componentei principale:

$$\begin{aligned} PCA : \quad & \max_{x \in \mathbb{R}^n} \|Sx\|_2^2 \\ & \text{s.l. } \|x\| = 1 \end{aligned}$$

Rezultatul pentru  $X = \begin{bmatrix} 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \\ 15 & 0.1 & 0.5 & -100 & -1.01 & 0.00001 \end{bmatrix}$  este

$$x^* = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$





$$\begin{aligned} (POCel :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } Ax = b, \end{aligned}$$

unde  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ .

- $f$  funcție diferențiabilă (netedă)
- $Q = \{x \in \mathbb{R}^n : a_i^T x = b_i, \forall i = 1, \dots, m\} \Rightarrow$  proiecție costisitoare.
- $x^*$  minim local:  $f(x^*) \leq f(x)$  pentru  $x \in Q$  în vecinătatea lui  $x^*$



$$(POCel :) \quad \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } Ax = b,$$

unde  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ .

- Funcția Lagrange  $\mathcal{L} : \text{dom}(f) \times \mathbb{R}^m$ :

$$\mathcal{L}(x, \mu) = f(x) + \mu^T (Ax - b)$$

- $\mu \in \mathbb{R}^m$  multiplicatori Lagrange (variabile duale).



$$\begin{aligned} (POCel :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } Ax = b, \end{aligned}$$

unde  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ .

### Teoremă (Multiplicatori Lagrange)

*Dacă  $x^*$  minim local, atunci există  $\mu^*$  astfel încât:*

$$\nabla_x \mathcal{L}(x^*, \mu^*) := \nabla f(x^*) + \mu_1^* a_1 + \mu_2^* a_2 + \cdots + \mu_m^* a_m = 0 \quad (\text{optimalitate})$$

$$\nabla_\mu \mathcal{L}(x^*, \mu^*) := Ax^* - b = 0. \quad (\text{fezabilitate})$$

*Dacă  $f$  convexă, atunci condițiile de mai sus sunt suficiente.*



**Demonstrație pe scurt** [ $\text{rank} A = p < n$ ]:

$$\begin{aligned} x^* &= \pi_Q(x^* - \nabla f(x^*)) = \arg \min_{Az=b} \|z - x^* + \nabla f(x^*)\| \\ &= x^* + \arg \min_{As=0} \|s + \nabla f(x^*)\|. \end{aligned}$$

Reamintim:  $v = \pi_{\text{Ker}(A)}(v) + \pi_{\text{Im}(A^T)}(v)$


$$0 = \arg \min_{As=0} \|s + \nabla f(x^*)\| \Rightarrow -\nabla f(x^*) \in \text{Im}(A^T)$$

Concluzie:

$$\exists \mu^* \in \mathbb{R}^m : -\nabla f(x^*) = A^T \mu^*.$$




$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1^2 - x_2^2 \\ \text{s.t.} \quad & x_2 = 0. \end{aligned}$$



$$\min_{x \in \mathbb{R}^2} x_1^2 + x_2^2 - x_1 x_2$$

$$\text{s.t. } x_1 - x_2 = 0.$$



$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|x - y\|_2^2 \\ \text{s.l.} \quad & a^T x = b, \end{aligned}$$

unde  $a \in \mathbb{R}^n, b \in \mathbb{R}$ .



$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} x^T H x + q^T x \\ \text{s.t.} \quad & A x = b, \end{aligned}$$

unde  $H \succeq 0$ ,  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ .

Condiții de optimalitate:

$$Hx^* + q + A^T \mu^* = 0 \quad (\text{optimalitate})$$

$$Ax^* = b. \quad (\text{fezabilitate})$$





$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} x^T H x + q^T x \\ \text{s.t.} \quad & A x = b, \end{aligned}$$

unde  $H \succeq 0$ ,  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ .

Condiții de optimalitate (Sistem Kuhn-Tucker):

$$\begin{bmatrix} H & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x^* \\ \mu^* \end{bmatrix} = \begin{bmatrix} -q \\ b \end{bmatrix}.$$



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

- $f, g_i$  sunt funcții netede



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

- $f, g_i$  sunt funcții netede
- $Q = \{x \in \mathbb{R}^n : g_i(x) = 0, \forall i = 1, \dots, m\} \Rightarrow$  proiecție dificilă



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

- $f, g_i$  sunt funcții netede
- $Q = \{x \in \mathbb{R}^n : g_i(x) = 0, \forall i = 1, \dots, m\} \Rightarrow$  proiecție dificilă
- $x^*$  minim local:  $f(x^*) \leq f(x)$  pentru  $x \in Q$  în vecinătatea lui  $x^*$



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l.} \quad & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

- Funcția Lagrange  $\mathcal{L} : \text{dom}(f) \times \mathbb{R}^m$ :

$$\mathcal{L}(x, \mu) = f(x) + \mu^T g(x)$$

- $\mu$  multiplicatori Lagrange (variabile duale)



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

### Definiție

*Punctul  $x^*$  este minim regulat dacă  $f(x), g_i(x)$  sunt continuu diferențiabile în vecinătatea lui  $x^*$  și  $\{\nabla g_i(x^*)\}$  sunt liniar independenți.*



$$\min_{x \in \mathbb{R}^2} x_2$$

$$\text{s.t. } (x_1 - 1)^2 + x_2^2 - 1 = 0, \quad (x_1 + 1)^2 + x_2^2 - 1 = 0$$






## Condiții de optimalitate (caz neliniar)

$$\min_{x \in \mathbb{R}^2} x_2$$

$$\text{s.t. } (x_1 - 1)^2 + x_2^2 - 1 = 0, \quad (x_1 + 1)^2 + x_2^2 - 1 = 0$$



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l.} \quad & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

### Teoremă (Multiplicatori Lagrange)

*Dacă  $x^*$  minim regulat, atunci există  $\mu^*$  astfel încât:*

$$\nabla_x \mathcal{L}(x^*, \mu^*) := \nabla f(x^*) + \mu_1^* \nabla g_1(x^*) + \mu_2^* \nabla g_2(x^*) + \dots + \mu_m^* \nabla g_m(x^*) = 0 \text{ (opt.)}$$


$$\nabla_\mu \mathcal{L}(x^*, \mu^*) := g(x^*) = 0 \text{ (fezabilitate)}$$



$$\begin{aligned}
 (POC_e : ) \quad & \min_{x \in \mathbb{R}^n} f(x) \\
 \text{s.l. } & g_i(x) = 0 \quad \forall i = 1, \dots, m
 \end{aligned}$$

## Definiție (Plan tangent)

Fie  $Q = \{x : g_i(x) = 0, i = 1, \dots, m\}$ , unde  $g_i$  diferentiabile în jurul lui  $y$ . Mulțimea direcțiilor tangente în punctul  $y$  este descrisă de  $T(x) = \{s : \nabla g_i(x)^T s = 0 \quad \forall i = 1, \dots, m\}$ .



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

### Teoremă (Condiții necesare ord. 2)

*Dacă  $x^*$  minim regulat și  $f$  și  $g_i$  dublu diferențiabile în jurul lui  $x^*$ . Atunci există  $\mu^*$  astfel încât:*

$$s^T \nabla^2 \mathcal{L}(x^*, \mu^*) s \geq 0 \quad \forall s \in T(x^*)$$

*unde  $T(x^*) = \{s : \nabla g_i(x^*)^T s = 0 \quad \forall i = 1, \dots, m\}$ .*

Echivalent,  $\nabla_x^2 \mathcal{L}(x^*, \mu^*)$  pozitiv semidefinită pe planul tangent  $T(x^*)$ .



$$\begin{aligned} (POCe : ) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

### Teoremă (Condiții suficiente ord. 2)

*Fie  $g_i(x^*) = 0$ ,  $f$  și  $g_i$  dublu diferențiabile în jurul lui  $x^*$ . Mai mult, presupunem  $\{\nabla g_i(x^*)\}$  liniar independenți. Atunci dacă:*

$$s^T \nabla^2 \mathcal{L}(x^*, \mu^*) s > 0 \quad \forall s \in T(x^*)$$

*unde  $T(x^*) = \{s : \nabla g_i(x^*)^T s = 0 \quad \forall i = 1, \dots, m\}$ , atunci  $x^*$  este minim local.*

Dacă  $\nabla_x^2 \mathcal{L}(x^*, \mu^*)$  este pozitiv definită pe planul tangent  $T(x^*)$  atunci  $x^*$  este minim local.



Exemplu:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1^2 - x_2^2 \\ \text{s.l.} \quad & x_2 = 0. \end{aligned}$$



- $\min_x \sum_{i=1}^n x_i^2$  s.l.  $\sum_{i=1}^n x_i = 1$
- $\min_x \sum_{i=1}^n x_i$  s.l.  $\sum_{i=1}^n x_i^2 = 1$
- $\min_x x^T A x$  s.l.  $\sum_{i=1}^n x_i^2 = 1$
- $\min_x \|x\|^2$  s.l.  $x^T A x = 1$



- Constrângeri de egalitate
- Condiții de optimalitate
- Filtrare de trend





Fie seria de timp  $\{y_t\}_{t=1}^n \in \mathbb{R}^n$ , presupunem descompunerea:


$$y_t = x_t + \epsilon_t,$$

- $x_t$  reprezintă componenta-trend de variație lentă
- $\epsilon_t$  componenta zgomot de variație rapidă

*Filtrare a trend-ului* = estimarea componentei "netede"  $x_t$



## Serii de timp: Filtrare trend



$$\min_x \frac{1}{2} \sum_{t=1}^n (x_t - y_t)^2 + \rho \sum_{t=2}^{n-1} (x_{t-1} - 2x_t + x_{t+1})^2. \quad (1)$$

- Funcția obiectiv urmărește reducerea reziduului  $\{y_t - x_t\}$  și, în același timp, ajustarea "netezimii" lui  $x_t$ .
- Diferența de ordin 2:  $x_{t-1} - 2x_t + x_{t+1}$  este nulă dacă și numai dacă  $\{x_{t-1}, x_t, x_{t+1}\}$  sunt coliniare.



În forma restrânsă:

$$x_{HP}^* := \operatorname{argmin}_x \frac{1}{2} \|x - y\|_2^2 + \rho \|Dx\|_2^2, \quad \text{unde } D \in \mathbb{R}^{(n-2) \times n}$$

$$D = \begin{bmatrix} 1 & -2 & 1 & & & & \\ & 1 & -2 & 1 & & & \\ & & \vdots & \vdots & \vdots & & \\ & & & 1 & -2 & 1 & \\ & & & & 1 & -2 & 1 \end{bmatrix}$$

Soluția modelului HP are forma:

$$x_{HP}^* := \left( I + 2\rho D^T D \right)^{-1} y.$$

Eroarea relativă de estimare satisface:

$$\|y - x_{HP}^*\|_2 \leq \frac{32\rho}{1 + 32\rho} \|y\|_2$$



$$x_{\ell_1}^* := \operatorname{argmin}_x \frac{1}{2} \|x - y\|_2^2 + \rho \|Dx\|_1$$

- $\|\cdot\|_2^2$  devine  $\|\cdot\|_1$
- Dacă  $D = I_n$  atunci problema este separabilă:  
 $x_t^* = \operatorname{argmin}_{x_t \in \mathbb{R}} \frac{1}{2} (x_t - y_t)^2 + \lambda |x_t|$



Reformulăm:

$$\begin{aligned} x_{\ell_1}^* &:= \operatorname{argmin}_x \frac{1}{2} \|x - y\|_2^2 + \rho \|z\|_1 \\ \text{s.t. } Dx &= z \end{aligned}$$

Funcția Lagrangian:

$$\mathcal{L}(x, z, \lambda) := \frac{1}{2} \|x - y\|_2^2 + \rho \|z\|_1 + \lambda^T (Dx - z)$$

Observăm:

$$[z(x, \lambda)]_i := \begin{cases} 0, & \text{dacă } -\rho \leq \lambda_i \leq \rho \\ -\infty, & \text{dacă } |\lambda_i| > \rho. \end{cases}$$



Condiții de optimalitate:

$$x_{\ell_1}^* = y - D^T \lambda^*$$

Problema duală:

$$\begin{aligned} \lambda^* = \arg \max_{\lambda} \quad & -\frac{1}{2} \|D^T \lambda\|_2^2 + \lambda^T D y \\ \text{s.l.} \quad & -\rho \leq \lambda_i \leq \rho \quad \forall i = 1, \dots, n-2. \end{aligned}$$



