

# TEHNICI DE OPTIMIZARE

## Curs 7

Andrei Pătrașcu

Departament Informatică  
Universitatea din București

- **Constrângeri de egalitate. Condiții de optimalitate**
- Algoritmi pentru constrângeri de egalitate
- Metode de penalitate



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$




$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.t.} \quad & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$


- Funcția Lagrange  $\mathcal{L} : \text{dom}(f) \times \mathbb{R}^m$ :

$$\mathcal{L}(x, \mu) = f(x) + \mu^T g(x)$$


- $\mu$  multiplicatori Lagrange (variabile duale)







# Condiții de optimalitate (caz neliniar)



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

### Definiție (Plan tangent)

Fie  $Q = \{x : g_i(x) = 0, i = 1, \dots, m\}$ , unde  $g_i$  diferențiabile în jurul lui  $y$ . Mulțimea direcțiilor tangente în punctul  $y$  este descrisă de  $T(x) = \{s : \nabla g_i(x)^T s = 0 \quad \forall i = 1, \dots, m\}$ .





$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

### Definiție


*Punctul  $x^*$  este minim regulat dacă  $g_i(x)$  sunt continuu diferențiabile în vecinătatea lui  $x^*$  și  $\{\nabla g_i(x^*)\}$  sunt liniar independenți.*



## Condiții de optimalitate (caz neliniar)

$$\min_{x \in \mathbb{R}^2} x_2$$

$$\text{s.t. } (x_1 - 1)^2 + x_2^2 - 1 = 0, \quad (x_1 + 1)^2 + x_2^2 - 1 = 0$$



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l.} \quad & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

### Teoremă (Multiplicatori Lagrange)

*Dacă  $x^*$  minim regulat, atunci există  $\mu^*$  astfel încât:*

$$\nabla_x \mathcal{L}(x^*, \mu^*) := \nabla f(x^*) + \mu_1^* \nabla g_1(x^*) + \mu_2^* \nabla g_2(x^*) + \dots + \mu_m^* \nabla g_m(x^*) = 0 (\text{opt.})$$

$$\nabla_\mu \mathcal{L}(x^*, \mu^*) := g(x^*) = 0 \quad (\text{fezabilitate})$$



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

### Teoremă (Condiții necesare ord. 2)

*Dacă  $x^*$  minim regulat și  $f$  și  $g_i$  dublu diferențiabile în jurul lui  $x^*$ . Atunci există  $\mu^*$  astfel încât:*

$$s^T \nabla^2 \mathcal{L}(x^*, \mu^*) s \geq 0 \quad \forall s \in T(x^*)$$

*unde  $T(x^*) = \{s : \nabla g_i(x^*)^T s = 0 \quad \forall i = 1, \dots, m\}$ .*

Echivalent,  $\nabla_x^2 \mathcal{L}(x^*, \mu^*)$  pozitiv semidefinită pe planul tangent  $T(x^*)$ .



$$\begin{aligned} (POCe :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.l. } & g_i(x) = 0 \quad \forall i = 1, \dots, m \end{aligned}$$

### Teoremă (Condiții suficiente ord. 2)

*Fie  $g_i(x^*) = 0$ ,  $f$  și  $g_i$  dublu diferențiabile în jurul lui  $x^*$ . Mai mult, presupunem  $\{\nabla g_i(x^*)\}$  liniar independenți. Atunci dacă:*

$$s^T \nabla^2 \mathcal{L}(x^*, \mu^*) s > 0 \quad \forall s \in T(x^*)$$

*unde  $T(x^*) = \{s : \nabla g_i(x^*)^T s = 0 \quad \forall i = 1, \dots, m\}$ , atunci  $x^*$  este minim local.*

Dacă  $\nabla_x^2 \mathcal{L}(x^*, \mu^*)$  este pozitiv definită pe planul tangent  $T(x^*)$  atunci  $x^*$  este minim local.



Exemplu:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} \quad & x_1^2 - x_2^2 \\ \text{s.l.} \quad & x_2 = 0. \end{aligned}$$



- $\min_x \sum_{i=1}^n x_i^2$  s.l.  $\sum_{i=1}^n x_i = 1$
- $\min_x \sum_{i=1}^n x_i$  s.l.  $\sum_{i=1}^n x_i^2 = 1$
- $\min_x x^T A x$  s.l.  $\sum_{i=1}^n x_i^2 = 1$
- $\min_x \|x\|^2$  s.l.  $x^T A x = 1$



$$\min_x \sum_{i=1}^n x_i^2 \quad \text{s.t.} \quad \sum_{i=1}^n x_i = 1$$

Funcția Lagrangian:

$$\mathcal{L}(x, \mu) = x^T I_n x + \mu(e^T x - 1).$$

Sistem Kuhn-Tucker:

$$\nabla_x \mathcal{L}(x, \mu) = 2x + e\mu = 0$$

$$\nabla_\mu \mathcal{L}(x, \mu) = e^T x = 1.$$

Soluții? Puncte staționare sau optime locale?





$$\min_x \sum_{i=1}^n x_i \quad \text{s.t.} \quad \sum_{i=1}^n x_i^2 = 1$$

Funcția Lagrangian:

$$\mathcal{L}(x, \mu) = \mathbf{e}^T x + \mu(\|x\|_2^2 - 1).$$

Sistem Kuhn-Tucker:

$$\nabla_x \mathcal{L}(x, \mu) = \mathbf{e} + \mu x = 0$$

$$\nabla_\mu \mathcal{L}(x, \mu) = \|x\|_2^2 - 1 = 0.$$

Soluții? Indiciu:  $\nabla_x^2 \mathcal{L}(x, \mu) = 2\mu I_n$ .



$$\min_x x^T A x \quad \text{s.t.} \quad \sum_{i=1}^n x_i^2 = 1, \quad A \succ 0.$$

Funcția Lagrangian:

$$\mathcal{L}(x, \mu) = x^T A x + \mu(\|x\|_2^2 - 1).$$

Sistem Kuhn-Tucker:

$$\nabla_x \mathcal{L}(x, \mu) = A x + \mu x = 0$$

$$\nabla_\mu \mathcal{L}(x, \mu) = \|x\|_2^2 - 1 = 0.$$

Soluții? Indiciu:  $\nabla_x^2 \mathcal{L}(x, \mu) = 2A + 2\mu I_n$ .



$$Q = \{x : g_i(x) = 0 \quad \forall i = 1, \dots, m\}$$

$$\min_x f(x) + \iota_Q(x) = \begin{cases} f(x) & x \in Q \\ \infty & x \notin Q \end{cases}$$

Reformulare funcție indicator (multiplicatori Lagrange):

$$\iota_Q(x) = \max_{\mu \in \mathbb{R}^m} \mu^T g(x) \left( = \sum_i \mu_i g_i(x) \right) = \begin{cases} 0 & g(x) = 0 \\ \infty & g(x) \neq 0. \end{cases}$$



$$\min_x f(x) + \iota_Q(x) = \begin{cases} f(x) & x \in Q \\ \infty & x \notin Q \end{cases}$$

Echivalent (moltiplicatori Lagrange):

$$\min_x f(x) + \iota_Q(x) = \min_{x \in \mathbb{R}^n} \max_{\mu \in \mathbb{R}^m} f(x) + \mu^T g(x) = \begin{cases} f(x) & x \in Q \\ \infty & x \notin Q \end{cases}$$



$$\min_x f(x) + \iota_Q(x) = \begin{cases} f(x) & x \in Q \\ \infty & x \notin Q \end{cases}$$

Echivalent (multiplicatori Lagrange):

$$\min_x f(x) + \iota_Q(x) = \min_{x \in \mathbb{R}^n} \max_{\mu \in \mathbb{R}^m} f(x) + \mu^T g(x) = \begin{cases} f(x) & x \in Q \\ \infty & x \notin Q \end{cases}$$

$$[\text{Pentru } \mu = \mu^* \text{ m\u0103rgini\u021bi}] \min_x f(x) + \iota_Q(x) = \min_{x \in \mathbb{R}^n} f(x) + (\mu^*)^T g(x)$$



- Constrângeri de egalitate. Condiții de optimalitate
- **Algoritmi pentru constrângeri de egalitate**
- Metode de penalitate



Metoda Gradientului Proiectat cu liniarizare:

$$x^{k+1} = \arg \min_z f(x^k) + \nabla f(x^k)^T (z - x^k) + \frac{1}{2\alpha_k} \|z - x^k\|^2$$

$$\text{s.l. } g_i(x^k) + \nabla g_i(x^k)^T (z - x^k) = 0 \quad \forall i = 1, \dots, m.$$

- Aproximarea pătratică a funcției obiectiv în stil MG
- Aproximarea liniară a constrângerilor (în jurul lui  $x^k$ )
- Pt constrângeri liniare se reduce la MGP



$$\min_x f(x) \text{ s.l. } \sum_i x_i = 1$$

Metoda Gradientului Proiectat cu liniarizare:

$$x^{k+1} = \arg \min_z f(x^k) + \nabla f(x^k)^T (z - x^k) + \frac{1}{2\alpha_k} \|z - x^k\|^2$$
$$\text{s.l. } \sum_i z_i = 0.$$

Soluție explicită:

$$x^{k+1} = \left( I_n - \frac{1}{n} e \cdot e^T \right) (x^k - \alpha \nabla f(x^k))$$





$$\min_x f(x) \text{ s.l. } g(x) = 0$$

Metoda Gradientului Proiectat cu liniarizare:

$$x^{k+1} = \arg \min_z \|z - (x^k - \alpha \nabla f(x^k))\|^2 \text{ s.l. } \nabla g(x^k)z = \nabla g(x^k)x^k - g(x^k)$$

Notăm  $G^k := \nabla g(x^k)$ ,  $g^k := \nabla g(x^k)x^k - g(x^k)$ , atunci

$$x^{k+1} = \left( I_n - [G^k]^\dagger G^k \right) (x^k - \alpha \nabla f(x^k)) + [G^k]^\dagger g^k.$$



Metoda Gradientului Proiectat cu liniarizare:

$$x^{k+1} = \arg \min_z f(x^k) + \nabla f(x^k)^T (z - x^k) + \frac{1}{2\alpha_k} \|z - x^k\|^2$$

$$\text{s.l. } g_i(x^k) + \nabla g_i(x^k)^T (z - x^k) = 0 \quad \forall i = 1, \dots, m.$$

## Teoremă

*Fie  $f, g_i$  astfel încât  $\nabla^2 f(x), \nabla^2 g_i(x)$  sunt continue Lipschitz. MGP cu liniarizare converge local la un minim (nesingular), cu rată liniară.*



Metoda Gradient Primal-Dual (Arrow-Hurwicz):

$$\begin{aligned}x^{k+1} &:= x^k - \alpha \nabla_x \mathcal{L}(x^k, \mu^k) \quad \left( = x^k - \alpha [\nabla f(x^k) + \nabla g(x^k)^T \mu^k] \right) \\ \mu^{k+1} &:= \mu^k + \alpha \nabla_\mu \mathcal{L}(x^k, \mu^k) \quad \left( = \mu^k + \alpha g(x^k) \right)\end{aligned}$$

- Pas de MG pentru minimizarea în  $x$
- Pas de MG pentru maximizarea în  $\mu$
- Dacă  $\mu^0 = \mu^*$  atunci MGPD se reduce la MG pe  $\mathcal{L}(x, \mu^*)$



Metoda Gradient Primal-Dual (Arrow-Hurwicz):

$$\begin{aligned}x^{k+1} &:= x^k - \alpha \nabla_x \mathcal{L}(x^k, \mu^k) & \left( = x^k - \alpha [\nabla f(x^k) + \nabla g(x^k)^T \mu^k] \right) \\ \mu^{k+1} &:= \mu^k + \alpha \nabla_\mu \mathcal{L}(x^k, \mu^k) & \left( = \mu^k + \alpha g(x^k) \right)\end{aligned}$$

## Teoremă

*Fie  $f, g_i$  astfel încât  $\nabla^2 f(x), \nabla^2 g_i(x)$  sunt continue Lipschitz. Metoda Arrow-Hurwicz converge local la un minim (nesingular), cu rată liniară.*



- Constrângeri de egalitate. Condiții de optimalitate
- Algoritmi pentru constrângeri de egalitate
- **Metode de penalitate**




$$\min_x f(x) \text{ s.l. } x \in Q$$

Funcție penalitate asociată mulțimii fezabile  $Q$ :


- (i)  $\phi$  continuu diferențiabilă și strict convexă pe  $Q$
- (ii)  $\phi(0) = 0$  și  $\nabla\phi(0) = 0$
- (iii)  $\lim_{t \rightarrow -\infty} \nabla\phi(t) = -\infty$  și  $\lim_{t \rightarrow \infty} \nabla\phi(t) = \infty$




# Funcție penalitate




$$\phi(x) = \frac{2}{3}|x|^{3/2}$$




$$\phi(x) = \frac{1}{2}|x|^2$$



$$\phi(x) = \frac{1}{3}|x|^3$$



$$\phi(x) = \frac{1}{10}|x|^{10}$$



$$\min_x f(x) \text{ s.l. } x \in Q$$

Funcția de penalitate aproximează funcția indicator asociată mulțimii  $Q$ :

$$\min_x \phi(\|g(x)\|) = 0$$

$$\arg \min_x \phi(\|g(x)\|) = Q$$

Aproximăm (POCe) cu:

$$x_\rho^* := \arg \min_x f(x) + \rho \phi(\|g(x)\|)$$

Observăm:

- $\min_x \lim_{\rho \rightarrow \infty} f(x) + \rho \phi(\|g(x)\|) = f^*$
- $\exists \alpha(\rho), \beta(\rho) > 0 : f^* - f(x_\rho^*) \leq \alpha(\rho), \|g(x)\| \leq \beta(\rho)$






Alegerea funcției de penalitate:

$$\begin{aligned} \min_x \quad & f(x) := -x^4 \\ \text{s.l. } & g(x) := x = 0. \end{aligned}$$

[ $\phi$  pătratic]  $x_\rho^* = \arg \min_x f(x) + \rho g(x) = -x^4 + \rho x^2.$



Alegerea funcției de penalitate:

$$\begin{aligned} \min_x \quad & f(x) := -x^4 \\ \text{s.l. } & g(x) := x = 0. \end{aligned}$$

$$[\phi \text{ polinomial}] \quad x_\rho^* = \arg \min_x -x^4 + \rho x^2 + x^\gamma.$$

Când există  $x_\rho^*$ ?



$$\min_x f(x) \text{ s.l. } g(x) = 0$$

Funcție penalitate pătratică ( $\rho > 0$ ):

$$\min_x f(x) + \rho \sum_i (g_i(x))^2.$$

- Fie  $\rho_1 \leq \rho_2$  și  $x_\rho^* = \arg \min_x f(x) + \rho \sum_i (g_i(x))^2$ , atunci:

$$\sum_i (g_i(x_{\rho_2}^*))^2 \leq \sum_i (g_i(x_{\rho_1}^*))^2.$$

- $\rho \rightarrow \infty$  atunci  $g_i(x) \rightarrow 0$



Considerăm:  $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$

- $\min_x 0$  s.l.  $Ax = b$
- $\min_x c^T x$  s.l.  $Ax = b$
- $\min_x \|x\|_2^2$  s.l.  $Ax = b$
- $\min_x \frac{1}{2}x^T Hx + q^T x$  s.l.  $Ax = b, \quad H \succ 0.$
- $\min_x \frac{1}{2}\|Ax - b\|_2^2$  s.l.  $\|x\| = 1$



Metoda de Penalitate Pătratică:

$$x^k = \arg \min_{x \in Q_0} f(x) + \frac{\rho_k}{2} \|g(x)\|^2 \quad \rho_k \rightarrow \infty.$$

## Teoremă

*Considerăm  $X^* \neq \emptyset$ . Fie  $f, g_i$  funcții continue și  $Q_0$  mărginită,  $Q_0 \cap X^* \neq \emptyset$ . Atunci punctele limită ale șirului generat de MP sunt minime globale ale problemei (POCe).*



Metoda de Penalitate:

$$x^k = \arg \min_{x \in \mathbb{R}^n} f(x) + \frac{\rho_k}{2} \|g(x)\|^2 \quad \rho_k \rightarrow \infty.$$

- pentru mărginirea domeniului, eventual, înlocuim  $\mathbb{R}^n$  cu  $Q_0$
- la fiecare iterație se rezolvă subproblema (posibil neconvexă)  
 $\min_x f(x) + \frac{\rho_k}{2} \|g(x)\|^2$
- $\|g(x^k)\| \rightarrow 0$  când  $\rho_k \rightarrow \infty$ !



Metoda de Penalitate:

$$x^k = \arg \min_{x \in \mathbb{R}^n} f_{\rho_k}(x) := f(x) + \frac{\rho_k}{2} \|g(x)\|^2 \quad \rho_k \rightarrow \infty.$$

- Scenariu 1: Soluția  $x^k$  nu există
- Exemplu!



Metoda de Penalitate:

$$x^k = \arg \min_{x \in \mathbb{R}^n} f_{\rho_k}(x) := f(x) + \frac{\rho_k}{2} \|g(x)\|^2 \quad \rho_k \rightarrow \infty.$$

- Scenariu 2: Soluția  $x^k$  există, dar  $\{x^k\}_{k \geq 0}$  nu converge.
- Exemplu 1:  $Q = \emptyset$
- Exemplu 2:  $f = 0$  și  $\nabla g(x^*)$  defectiv de rang





$$\begin{aligned} \min_x \quad & 0 \\ \text{s.t.} \quad & x_1^2 = 3, \quad -2x_1 + x_2^2 = 0 \end{aligned}$$

$$Q = \{[\sqrt{3} \quad \pm 2\sqrt{3}]^T\}$$

$$\text{Pentru } z = \begin{bmatrix} -1 \\ 0 \end{bmatrix}$$

$$\nabla f_\rho(z) := \rho \nabla g(z) g(z) = \begin{bmatrix} -2 & -2 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} -2 \\ 2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$



Metoda de Penalitate:

$$x^k = \arg \min_{x \in Q_0} f(x) + \frac{\rho_k}{2} \|g(x)\|^2 \quad \rho_k \rightarrow \infty.$$

- la fiecare iterație se rezolvă subproblema  $\min_x f(x) + \frac{\rho_k}{2} \|g(x)\|^2$
- $\|g(x^k)\| \rightarrow 0$  când  $\rho_k \rightarrow \infty$ !
- Pentru  $\rho$  mare crește numărul de condiționare al subproblemei.
- Rată de convergență:  $\|x^k - x^*\| = O(1/\rho_k)$



- 1 Luenberger, David G., and Yinyu Ye. Linear and nonlinear programming. Vol. 2. Reading, MA: Addison-wesley, 1984.

