

TEHNICI DE OPTIMIZARE

Curs 10

Andrei Pătrașcu

Departament Informatică
Universitatea din București

- Examenul s-a stabilit pe 16.05.2025 (ora 9)
- Examenul va avea loc cu materiale la dispoziție
- Materialele vor fi doar fizice, nimic electronic
- Examenul va dura 2h



- **Algoritmi pentru (POCi) convexe.**
- Recapitulare:
 - Mulțimi și funcții convexe.
 - Algoritmi pentru (POfC).
 - Algoritmi pentru (POCi) .
 - Dualitate și optimalitate.



QP dimensiune n :

$$\min_x \frac{1}{2}x^T Hx + c^T x \text{ s.t. } Ax \leq b.$$

Problema este convexă $H \succ 0$, m constrângeri liniare \Rightarrow dualitate tare

$$\mathcal{L}(x, \lambda) = \frac{1}{2}x^T Hx + c^T x + \lambda^T (Ax - b)$$

$$\phi(\lambda) = \min_x \frac{1}{2}x^T Hx + (c + A^T \lambda)^T x - \lambda^T b$$



Kuhn-Tucker:

$$Hx + c + A^T \lambda = 0$$

$$\lambda_i (A_i x - b_i) = 0 \quad \forall i = 1, \dots, m$$

$$Ax \leq b, \lambda \geq 0.$$

Forma soluției primale:

$$x(\lambda) = H^{-1}(c + A^T \lambda)$$

$$\phi(\lambda) = -\frac{1}{2}(c + A^T \lambda)^T H^{-1}(c + A^T \lambda) - \lambda^T b.$$

Problema duală: QP dimensiune m

$$\max_{\lambda \geq 0} -\frac{1}{2}(c + A^T \lambda)^T H^{-1}(c + A^T \lambda) - \lambda^T b$$



$$\min_x f(x) \text{ s.l. } g(x) \leq 0.$$

Metoda Gradientului Dual:

$$x^{k+1} = \arg \min_x \mathcal{L}(x, \lambda^k)$$

$$\lambda^{k+1} = \pi_{\geq 0}(\lambda^k + \alpha g(x^{k+1}))$$



$$\min_x f(x) \text{ s.l. } g(x) \leq 0.$$

Problema duală:

$$\max_{\lambda \geq 0} \phi(\lambda), \quad \phi(\lambda) = \min_x \mathcal{L}(x, \lambda)$$

- notăm $x(\lambda) = \arg \min_x \mathcal{L}(x, \lambda)$
- Dacă f este σ -tare convexă, atunci $\nabla \phi(\lambda) = g(x(\lambda))$ este $\frac{1}{\sigma}$ -continuu Lipschitz



$$\min_x f(x) \text{ s.l. } g(x) \leq 0.$$


Metoda Gradientului Dual:

$$\lambda^{k+1} = \pi_{\geq 0}(\lambda^k + \alpha \nabla \phi(\lambda^k))$$

- Iterația este identică cu MGP pentru problema duală!
- $\lambda^k \rightarrow \lambda^* \Rightarrow x(\lambda^k) \rightarrow x^*$



$$\min_x \|x - y\|_2^2 \text{ s.t. } Ax \leq b.$$



$$\min_x \|x - y\|_2^2 \text{ s.t. } Ax \leq b.$$

$$y = \begin{bmatrix} 1 \\ 3 \end{bmatrix} \quad A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ -1 & 0 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix}$$

$$\mathcal{L}(x, \lambda) = \|x - y\|_2^2 + \lambda^T (Ax - b)$$

$$\phi(\lambda) = \min_x \mathcal{L}(x, \lambda)$$

$$\text{Problema duală: } \max_{\lambda \geq 0} -\frac{1}{4} \|A^T \lambda\|_2^2 + \lambda^T (Ay - b)$$



Problema proiecției ortogonale:

$$\min_x \|x - y\|_2^2 \text{ s.l. } Ax \leq b.$$

$$\nabla \phi(\lambda) = -\frac{1}{2}AA^T\lambda + (Ay - b)$$



Metoda Gradientului Dual:

$$\lambda^{k+1} = \pi_{\geq 0} \left(\left[I - \alpha \frac{1}{2} A A^T \right] \lambda^k + \alpha (A y - b) \right)$$

Exercițiu

Pornind din $\lambda^0 = [1 \ 1 \ 1]$, calculați un pas de MGD cu pas constant $\alpha = \frac{1}{L}$.



- Algoritmi pentru (POCi) convexe.
- **Recapitulare:**
 - Mulțimi și funcții convexe.
 - Algoritmi pentru (POfC).
 - Algoritmi pentru (POCi) .
 - Dualitate și optimalitate.






Definiție

Mulțimea Q este **convexă** dacă și numai dacă $\forall x, y \in Q$

$$\alpha x + (1 - \alpha)y \in Q \quad \forall \alpha \in [0, 1].$$

Mai mult, Q este **închisă** dacă își conține toate punctele limită ale șirurilor din Q .

Pe scurt: segmentul aflat între oricare două puncte ale mulțimii se află, de asemenea, în mulțime.



Fie $C_1, C_2, \dots, C_m \subset \mathbb{R}^n$ mulțimi convexe închise.

- *Intersecția*: mulțimea $C = \bigcap_{i=1}^m C_i$ este închisă și convexă



Fie $C_1, C_2, \dots, C_m \subset \mathbb{R}^n$ mulțimi convexe închise.

- *Intersecția*: mulțimea $C = \bigcap_{i=1}^m C_i$ este închisă și convexă
- *Produs cartezian*: mulțimea $C = C_1 \times C_2 \times \dots \times C_m$ este închisă și convexă.



Fie $C_1, C_2, \dots, C_m \subset \mathbb{R}^n$ mulțimi convexe închise.

- *Intersecția*: mulțimea $C = \bigcap_{i=1}^m C_i$ este închisă și convexă
- *Produs cartezian*: mulțimea $C = C_1 \times C_2 \times \dots \times C_m$ este închisă și convexă.
- *Compunerea cu un operator afin*: fie $A \in \mathbb{R}^{p \times n}$, $b \in \mathbb{R}^p$, mulțimea $C'_i = \{z \in C_i : Az = b\}$ este închisă și convexă.



- $\{x \in \mathbb{R}^2 : -1 \leq x_1 + x_2 - 2 \leq 1\}$



- $\{x \in \mathbb{R}^2 : -1 \leq x_1 + x_2 - 2 \leq 1\}$
- $\{x \in \mathbb{R}^2 : -1 \leq x_1^2 + x_2 \leq 1\}$




- $\{x \in \mathbb{R}^2 : -1 \leq x_1 + x_2 - 2 \leq 1\}$
- $\{x \in \mathbb{R}^2 : -1 \leq x_1^2 + x_2 \leq 1\}$
- $\{x \in \mathbb{R}^2 : x \geq 0, x_1^2 - x_2^2 \leq 1\}$



Funcția scalară $f : \mathbb{R}^n \rightarrow (-\infty, +\infty]$ este convexă dacă:

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \quad \forall \alpha \in [0, 1]$$



Fie $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$ funcții convexe închise.

- *Suma*: pentru $\alpha \in \mathbb{R}_+^m$, funcția $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$ este închisă și convexă



Fie $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$ funcții convexe închise.

- *Suma*: pentru $\alpha \in \mathbb{R}_+^m$, funcția $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$ este închisă și convexă
- *Maximum*: funcția $f(x) = \max\{f_1(x), f_2(x), \dots, f_m(x)\}$ este închisă și convexă.



Fie $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$ funcții convexe închise.

- *Suma*: pentru $\alpha \in \mathbb{R}_+^m$, funcția $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$ este închisă și convexă
- *Maximum*: funcția $f(x) = \max\{f_1(x), f_2(x), \dots, f_m(x)\}$ este închisă și convexă.
- *Compunerea interioară cu un operator afin*: fie $A \in \mathbb{R}^{p \times n}$, $b \in \mathbb{R}^p$, funcția $g(x) = f(Ax - b)$ este închisă și convexă.



Fie $f_1, f_2, \dots, f_m : \mathbb{R}^n \rightarrow \mathbb{R}$ funcții convexe închise.

- *Suma*: pentru $\alpha \in \mathbb{R}_+^m$, funcția $f(x) = \sum_{i=1}^m \alpha_i f_i(x)$ este închisă și convexă
- *Maximum*: funcția $f(x) = \max\{f_1(x), f_2(x), \dots, f_m(x)\}$ este închisă și convexă.
- *Compunerea interioară cu un operator afin*: fie $A \in \mathbb{R}^{p \times n}$, $b \in \mathbb{R}^p$, funcția $g(x) = f(Ax - b)$ este închisă și convexă.
- *Compunerea exterioară cu o funcție crescătoare*: fie $\phi : \mathbb{R} \rightarrow \mathbb{R}$ o funcție crescătoare, funcția $g(x) = \phi(f(x))$ este închisă și convexă.



- $\max\{0, (x_1 + x_2)^2 - 1\}$



- $\max\{0, (x_1 + x_2)^2 - 1\}$
- $\min\{1, |x|\}$



- $\max\{0, (x_1 + x_2)^2 - 1\}$
- $\min\{1, |x|\}$
- $|x_1 + x_2|^5 + 2^{x_1 - x_2}$



- $\max\{0, (x_1 + x_2)^2 - 1\}$
- $\min\{1, |x|\}$
- $|x_1 + x_2|^5 + 2^{x_1 - x_2}$
- $\log(1/x)$



- $\max\{0, (x_1 + x_2)^2 - 1\}$
- $\min\{1, |x|\}$
- $|x_1 + x_2|^5 + 2^{x_1 - x_2}$
- $\log(1/x)$
- $\log(1/(c^T x))$



- Algoritmi pentru (POCi) convexe.
- Mulțimi și funcții convexe.
- **Algoritmi pentru (POfC).**
- Algoritmi pentru (POCi) .
- Dualitate și optimalitate.



$$(POfC) : \quad \min_x f(x)$$

Teoremă (Fermat)

Presupunem funcția f diferențiabilă. Fie x^ un punct de minim al $f(\cdot)$ din \mathbb{R}^n , atunci: $\nabla f(x^*) = 0$.*

Teoremă

Presupunem funcția f este dublu diferențiabilă. Fie x^ un punct de minim al $f(\cdot)$ din \mathbb{R}^n , atunci: $\nabla^2 f(x^*) \succeq 0$.*

Teoremă

Presupunem funcția f este dublu diferențiabilă. Dacă $\nabla f(x^) = 0$ și:*

$$\nabla^2 f(x^*) \succ 0$$

atunci x^ este minim local.*

- $\min_x x_1^2 - x_2^2 + 2x_1x_2$



- $\min_x x_1^2 - x_2^2 + 2x_1x_2$
- $\min_x x_1^3 - x_2 + x_1x_2$



Definiție

O funcție $f \in S^\sigma$ este σ -tare convexă dacă satisface:

- *Ordin 0:*
$$f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y) - \alpha(1-\alpha)\frac{\sigma}{2}\|x-y\|^2, \quad \forall \alpha \in [0, 1], x, y$$
- *Ordin 1:* $f(x) \geq f(y) + \nabla f(y)^T(x-y) + \frac{\sigma}{2}\|x-y\|^2, \quad \forall x, y$
- *Ordin 2:* $\nabla^2 f(x) \succeq \sigma I_n \quad \forall x$

Exemple:

- $x \rightarrow (c^T x)^2 + \frac{1}{2}\|x\|_2^2$
- $x \rightarrow \|Ax - b\|_2^2 + \|x\|_2^2$
- $x \rightarrow \frac{1}{2}x^T Hx + q^T x, \quad H \succ 0$



Algorithm 1: Metoda Gradient ($x^0, \epsilon, \{\alpha_k\}_{k \geq 0}$):

Data: $k := 0$

```
1 while criteriu oprire = fals do  
2   |   Calculează:  $\nabla f(x^k)$   
3   |    $x^{k+1} = x^k - \alpha_k \nabla f(x^k)$   
4   |    $k := k + 1$   
5 end
```

- pas constant: $\alpha_k = \alpha$
- cea mai abruptă pantă: $\alpha_k = \arg \min_{\alpha} f(x^k - \alpha \nabla f(x^k))$
- adaptiv



Teoremă

Fie f diferentiabilă pe \mathbb{R}^n cu gradientul ∇f continuu Lipschitz:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|.$$

De asemenea, presupunem $\min_x f(x) > -\infty$ și $0 < \alpha < \frac{1}{2L}$. Atunci șirul generat de Metoda Gradient $x^{k+1} = x^k - \alpha \nabla f(x^k)$ satisface:

$$\lim_{k \rightarrow \infty} \nabla f(x^k) = 0,$$

$$\text{și } f(x^{k+1}) \leq f(x^k).$$

Teoremă (Rată de convergență (convexitate))

Fie f convexă cu gradientul ∇f continuu Lipschitz:

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|.$$

De asemenea, presupunem $\min_x f(x) > -\infty$ și $0 < \alpha < \frac{1}{2L}$. Atunci șirul generat de Metoda Gradient $x^{k+1} = x^k - \alpha \nabla f(x^k)$ satisface:

$$f(x^k) - f^* \leq \frac{L\|x^0 - x^*\|^2}{2k} \quad \forall k \geq 0.$$



Aproximarea pătratică în x^k

$$f(x) \approx f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T H_k (x - x^k)$$

Alegerea $H_k = \alpha I$ stă la baza MG.

Dacă funcția este dublu diferențiabilă atunci calitatea maximă aproximării se obține prin alegerea:

$$H_k := \nabla^2 f(x^k).$$



O nouă iterație (Newton):

$$x^{k+1} := \arg \min_x f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k)$$

La optim avem:

$$\nabla^2 f(x^k)(x^{k+1} - x^k) + \nabla f(x^k) = 0$$

$$\nabla^2 f(x^k)(x^{k+1} - x^k) = -\nabla f(x^k)$$

$$x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$$



Fie funcția pătratică:

$$f(x) = \frac{1}{2}x^T Ax - b^T x, \quad A \succ 0.$$

Metoda Newton converge într-un singur pas!

$$\begin{aligned} x^1 &= x^0 - [\nabla^2 f(x^0)]^{-1} \nabla f(x^0) \\ &= x^0 - A^{-1}(Ax^0 - b) = A^{-1}b =: x^* \end{aligned}$$

Cu cât f este mai aproape de o funcție pătratică, cu atât MN converge mai rapid.



Algorithm 2: Metoda Newton ($x^0, \epsilon, \{\alpha_k\}_{k \geq 0}$):

Data: $k := 0$

```
1 while criteriu oprire = fals do  
2   |   Calculează:  $d^k = [\nabla^2 f(x^k)]^{-1} \nabla f(x^k)$   
3   |    $x^{k+1} = x^k - \alpha_k d^k$   
4   |    $k := k + 1$   
5 end
```



Teoremă (Polyak, caz convex)

Fie f dublu diferențiabilă și $\nabla^2 f$ continuu Lipschitz cu constanta L :

$$\|\nabla^2 f(x) - \nabla^2 f(y)\| \leq L\|x - y\|.$$

De asemenea, presupunem f tare convexă cu constanta σ . Atunci, dacă iterația inițială satisface:

$$q = \frac{L}{2\sigma^2} \|\nabla f(x^0)\| < 1,$$

atunci x^k generat de MN cu pas constant $\alpha_k = 1$ converge pătratic la optimul global x^ , i.e.*

$$\|x^k - x^*\| \leq \frac{2\sigma}{L} q^{2^k}$$



Teoremă (Polyak, caz general neconvex)

Fie f dublu diferențiabilă într-o vecinătate U a unui minim local nesingular x^ . De asemenea, presupunem $\nabla^2 f$ continuu Lipschitz cu constanta L în U . Atunci, există δ astfel încât pentru:*

$$\|x^0 - x^*\| < \delta,$$

x^k generat de MN cu $\alpha_k = 1$ converge pătratic la optimul local x^ .*



1



Când există o soluție $\mathbb{E}[a_\xi x - b_\xi] = 0$ avem o problemă de interpolare liniară.

Interpolare

Definim $C = H_1 \cap \dots \cap H_m \neq \emptyset$, unde $H_i = \{x : a_i^T x = b_i\}$. Determinați un punct din mulțimea C , i.e. $x \in C$.



$$(POC) : \min_{x \in \mathbb{R}^n} f(x) \text{ supus la } x \in Q$$

- Q mulțime fezabilă (convexă, închisă)



$$(POC) : \min_{x \in \mathbb{R}^n} f(x) \text{ supus la } x \in Q$$

- Q mulțime fezabilă (convexă, închisă)
- se urmărește determinarea lui $x^* \in Q$ care asigură:

$$f(x^*) \leq f(x), \quad \forall x \in Q, \|x - x^*\| \leq \epsilon \text{ (minim local)}$$

$$f(x^*) \leq f(x), \quad \forall x \in Q \text{ (minim global)}$$



$$(POC) : \min_{x \in \mathbb{R}^n} f(x) \text{ supus la } x \in Q$$

- Q mulțime fezabilă (convexă, închisă)
- se urmărește determinarea lui $x^* \in Q$ care asigură:

$$f(x^*) \leq f(x), \quad \forall x \in Q, \|x - x^*\| \leq \epsilon \text{ (minim local)}$$

$$f(x^*) \leq f(x), \quad \forall x \in Q \text{ (minim global)}$$

- echivalent: $\min_x f(x) + I_Q(x)$, unde $I_Q(x) = \begin{cases} 0 & x \in Q \\ \infty & x \notin Q \end{cases}$



Numim mulțimea fezabilă simplă dacă următoarele obiecte pot fi calculate eficient:

- punct fezabil: $x \in Q$
- proiecția ortogonală: $\pi_Q(y) := \operatorname{argmin}_x \|x - y\|$ s.l. $x \in Q$
- oracol liniar: $\phi_Q(y) := \operatorname{argmin}_x x^T y$ s.l. $x \in Q$
- mulțimi active
- ...




O problemă particulară

Problema proiecției ortogonale Euclidiene:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|x - y\|_2^2 \\ \text{s.t.} \quad & x \in Q \end{aligned}$$

Soluția $\pi_Q(y)$: punctul cel mai apropiat de y , care aparține mulțimii fezabile Q



Problema proiecției ortogonale Euclidiene:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \frac{1}{2} \|x - y\|_2^2 \\ \text{s.l. } & x \in Q \end{aligned}$$

Soluția $\pi_Q(y)$: punctul cel mai apropiat de y , care aparține mulțimii fezabile Q

- Dacă Q este închisă atunci $\pi_Q(\cdot)$ există
- $y \in Q \rightarrow \pi_Q(y) = y$
- Condiții de optimalitate: $(y - \pi_Q(y))^T (x - \pi_Q(y)) \leq 0 \quad \forall x \in Q.$



- bila $Q := B(0, r) = \{x \in \mathbb{R}^n : \|x\| \leq r\} \Rightarrow \pi_Q(y) = \left\{1, \frac{r}{\|y\|}\right\} y$



- bila $Q := B(0, r) = \{x \in \mathbb{R}^n : \|x\| \leq r\} \Rightarrow \pi_Q(y) = \left\{1, \frac{r}{\|y\|}\right\} y$
- hiperparalelipiped
 $Q := [l, u]^n = \{x \in \mathbb{R}^n : x \in [l, u]\} \Rightarrow \pi_Q(y)_i = \max\{l_i, \min\{u_i, y_i\}\}$



- bila $Q := B(0, r) = \{x \in \mathbb{R}^n : \|x\| \leq r\} \Rightarrow \pi_Q(y) = \left\{1, \frac{r}{\|y\|}\right\} y$
- hiperparalelipiped
 $Q := [l, u]^n = \{x \in \mathbb{R}^n : x \in [l, u]\} \Rightarrow \pi_Q(y)_i = \max\{l_i, \min\{u_i, y_i\}\}$
- hiperplan $Q := H(a, b) = \{x \in \mathbb{R}^n : a^T x = b\} \Rightarrow \pi_Q(y) = y - \frac{a^T y - b}{\|a\|_2^2} a$



- bila $Q := B(0, r) = \{x \in \mathbb{R}^n : \|x\| \leq r\} \Rightarrow \pi_Q(y) = \left\{1, \frac{r}{\|y\|}\right\} y$
- hiperparalelipiped
 $Q := [l, u]^n = \{x \in \mathbb{R}^n : x \in [l, u]\} \Rightarrow \pi_Q(y)_i = \max\{l_i, \min\{u_i, y_i\}\}$
- hiperplan $Q := H(a, b) = \{x \in \mathbb{R}^n : a^T x = b\} \Rightarrow \pi_Q(y) = y - \frac{a^T y - b}{\|a\|_2^2} a$
- semispațiu
 $Q := S(a, b) = \{x \in \mathbb{R}^n : a^T x \leq b\} \Rightarrow \pi_Q(y) = y - \frac{\max\{0, a^T y - b\}}{\|a\|_2^2} a$



$$(POC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Dacă $Q = \mathbb{R}^n$ atunci în toate punctele staționare $\nabla f(x^*) = 0$.

Definiție

Fie f diferențiabilă, $x \in Q$ și $\alpha > 0$ atunci denumim **operator de gradient redus peste mulțimea Q** transformarea:

$$\mathcal{G}_Q(x; \alpha) = \frac{1}{\alpha} [x - \pi_Q(x - \alpha \nabla f(x))]$$

Dacă $Q = \mathbb{R}^n$ atunci $\mathcal{G}_Q(x; \alpha) = \nabla f(x)$.



Definiție

Fie f diferențiabilă, $x \in Q$ și $\alpha > 0$ atunci denumim **operator de gradient redus peste mulțimea Q** transformarea:

$$\mathcal{G}_Q(x; \alpha) = \frac{1}{\alpha} [x - \pi_Q(x - \alpha \nabla f(x))]$$

- $f(x) = \frac{1}{2} \|x - y\|^2$

$$\mathcal{G}(x; 1) = x - \pi_Q(x - (x - y)) = x - \pi_Q(y) = x - x^*$$



Definiție

Fie f diferentiabilă, $x \in Q$ și $\alpha > 0$ atunci denumim **operator de gradient redus peste mulțimea Q** transformarea:

$$\mathcal{G}_Q(x; \alpha) = \frac{1}{\alpha} [x - \pi_Q(x - \alpha \nabla f(x))]$$

- $f(x) = \frac{1}{2} \|x - y\|^2$

$$\mathcal{G}(x; 1) = x - \pi_Q(x - (x - y)) = x - \pi_Q(y) = x - x^*$$

- $f(x) = \frac{1}{2} \|Ax - b\|^2, Q = B(0; 1)$

$$\begin{aligned} \mathcal{G}(x; 1) &= x - \pi_Q(x - A^T(Ax - b)) = x - \pi_Q((I - A^T A)x + A^T b) \\ &= x - \frac{1}{\|(I - A^T A)x + A^T b\|} [(I - A^T A)x + A^T b] \\ &= (1 - \bar{\alpha})x + \bar{\alpha} \nabla f(x). \end{aligned}$$



$$(OPC) : \quad \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Pp. $x \in Q, \mathcal{G}(x) \neq 0$ atunci din definiția lui \mathcal{G} avem:

$$\begin{aligned} \alpha^2 \|\mathcal{G}(x; \alpha) - \nabla f(x)\|_2^2 &= \|\pi_Q(x - \alpha \nabla f(x)) - (x - \alpha \nabla f(x))\|_2^2 \\ &= \min_{z \in Q} \|z - (x - \alpha \nabla f(x))\|_2^2 \\ &\leq \|x - (x - \alpha \nabla f(x))\|_2^2 = \alpha^2 \|\nabla f(x)\|_2^2. \end{aligned}$$

Desfășurând norma rezultă:

$$\frac{1}{2} \|\mathcal{G}(x; \alpha)\|_2^2 \leq \nabla f(x)^T \mathcal{G}(x; \alpha).$$



$$(OPC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Dacă f diferențiabilă atunci:

$$\begin{aligned} f(x - \alpha \mathcal{G}(x; \alpha)) &= f(x) - \alpha \nabla f(x)^T \mathcal{G}(x; \alpha) + o(-\alpha \mathcal{G}(x; \alpha)) \\ &\leq f(x) - \alpha \frac{1}{2} \|\mathcal{G}(x; \alpha)\|_2^2 + o(-\alpha \mathcal{G}(x; \alpha)) \\ &\leq f(x) - \alpha \|\mathcal{G}(x; \alpha)\|_2 \left[\frac{1}{2} \|\mathcal{G}(x; \alpha)\|_2 - \frac{o(-\alpha \mathcal{G}(x; \alpha))}{\alpha \|\mathcal{G}(x; \alpha)\|_2} \right]. \end{aligned}$$

Un pas α suficient de mic asigură: $f(x - \alpha \mathcal{G}(x; \alpha)) < f(x)$, de aceea orice minim x^* satisface $\mathcal{G}(x^*; \alpha) = 0$.



$$(OPC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Teoremă

Fie f diferențiabilă, Q mulțime convexă închisă și α o constantă pozitivă. Orice minim x^ al problemei OPC satisface:*

$$x^* = \pi_Q(x^* - \alpha \nabla f(x^*)) \Leftrightarrow \mathcal{G}(x^*; \alpha) = 0$$

Mai mult, dacă f convexă atunci x^ soluția OPC dacă și numai dacă $\mathcal{G}(x^*; \alpha) = 0$.*

- Analog condițiilor de ordin I pentru cazul neconstrâns (i.e. $Q = \mathbb{R}^n$)



$$(OPC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Teoremă

Fie f diferențiabilă, Q mulțime convexă închisă și α o constantă pozitivă. Orice minim x^ al problemei OPC satisface:*

$$x^* = \pi_Q(x^* - \alpha \nabla f(x^*)) \Leftrightarrow \mathcal{G}(x^*; \alpha) = 0$$

Mai mult, dacă f convexă atunci x^ soluția OPC dacă și numai dacă $\mathcal{G}(x^*; \alpha) = 0$.*

- Analog condițiilor de ordin I pentru cazul neconstrâns (i.e. $Q = \mathbb{R}^n$)
- Condiții necesare în general, dar nec. și suficiente în cazul f convexă



$$(OPC) : \min_{x \in \mathbb{R}^n} f(x) \\ \text{s. l. } x \in Q.$$

Teoremă

Fie f diferențiabilă, Q mulțime convexă închisă și α o constantă pozitivă. Orice minim x^ al problemei OPC satisface:*

$$x^* = \pi_Q(x^* - \alpha \nabla f(x^*)) \Leftrightarrow \mathcal{G}(x^*; \alpha) = 0$$

Mai mult, dacă f convexă atunci x^ soluția OPC dacă și numai dacă $\mathcal{G}(x^*; \alpha) = 0$.*

- Analog condițiilor de ordin I pentru cazul neconstrâns (i.e. $Q = \mathbb{R}^n$)
- Condiții necesare în general, dar nec. și suficiente în cazul f convexă
- Cand π_Q este tractabil, condiția de mai sus este verificabilă!



Din relațiile de mai sus, pentru α suficient de mic obținem descreșterea:

$$f(x - \alpha \mathcal{G}(x)) < f(x)$$


care sugerează iterația $x^+ = x - \alpha \mathcal{G}(x)$.

Calcularea operatorului $\mathcal{G}(\cdot)$ folosește $\pi_Q(\cdot)$, care este tractabil doar în anumite cazuri particulare "simple": bilă, hipercub, hiperplan etc.



Metoda Gradientului Proiectat: inițial $x^0 \in Q$

$$x^{k+1} := x^k - \alpha \mathcal{G}(x^k) = \pi_Q(x^k - \alpha \nabla f(x^k))$$




[Polyak, pg. 234]



Interpretare:

$$\begin{aligned} x^{k+1} &= \operatorname{argmin}_z f(x^k) + \nabla f(x^k)^T(z - x^k) + \frac{1}{2\alpha_k} \|z - x^k\|^2 \\ &= \operatorname{argmin}_z \frac{1}{2} \|z - (x^k - \alpha_k \nabla f(x^k))\|^2 \quad (\text{exercitiu!}) \end{aligned}$$



[Polyak, pg. 234]



Algorithm 3: Metoda Gradientului Proiectat (MGP) $(x^0, \epsilon, \{\alpha_k\}_{k \geq 0})$:**Data:** $k := 0$

```

1 while criteriu oprire = fals do
2   |   Calculează:  $\nabla f(x^k)$ 
3   |    $x^{k+1} = \pi_Q(x^k - \alpha_k \nabla f(x^k))$ 
4   |    $k := k + 1$ 
5 end

```


Teoremă

Fie f o funcție diferențiable cu gradient Lipschitz și Q mulțimea fezabilă convexă. Pentru pasul $\alpha_k = \alpha \in (0, 2/L)$, șirul MGP satisface:

$$\|\mathcal{G}(x^k)\| \rightarrow 0 \text{ când } k \rightarrow \infty.$$

Mai mult, dacă f convexă și X^* mulțimea optimă POC, atunci $x^k \rightarrow x^* \in X^*$.

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|^2 \quad \text{s.t.} \quad l \leq x \leq u.$$



$$\begin{aligned} \min_{x \in \mathbb{R}^3} \quad & f(x) = x_1^2 + x_2^2 + x_3^2 + (x_1 + 2x_2 - 4)^2 \\ \text{s.l.} \quad & \|x\| \leq 1. \end{aligned}$$

Calculați prima iterație a MGP cu pas constant $\alpha = 1/L$, pornind din $x^0 = [0 \ 0 \ 0]$.



Teoremă (Nesterov, 2014)

Fie f o funcție diferențiabilă cu gradient Lipschitz cu constanta L , tare-convexă cu constanta σ , iar Q convexă și închisă. Pentru pasul $\alpha \in \left(0, \frac{2}{L+\sigma}\right]$ avem:

$$\|x^k - x^*\| \leq \left(1 - \frac{\sigma}{L}\right)^k \|x^0 - x^*\|$$

- Performanță similară cu cea a MG
- $x^k \in S_f(f^* + \epsilon)$ după $\mathcal{O}(\kappa \log(1/\epsilon))$ iterații



Ipoteza: Este posibilă calcularea eficientă a operatorului cost liniar:

$$\phi_Q(y) := \operatorname{argmin}_{z \in Q} y^T z$$




Ipoteza: Este posibilă calcularea eficientă a operatorului cost liniar:

$$\phi_Q(y) := \operatorname{argmin}_{z \in Q} y^T z$$

Metoda Gradientului Condițional realizează un model aproximativ liniar al costului și folosește soluția acestuia la fiecare iterație k :

$$\begin{aligned}\phi_Q(x^k) &:= \operatorname{argmin}_{z \in Q} \nabla f(x^k)^T z \\ x^{k+1} &= x^k + \alpha_k(\phi_Q(x^k) - x^k).\end{aligned}$$





Algorithm 4: Metoda Gradientului Condițional (MGC)

$(x^0, \epsilon, \{\alpha_k\}_{k \geq 0})$:

Data: $k := 0$

```
1 while criteriu oprire = fals do  
2   Calculează:  $\phi_Q(x^k) := \operatorname{argmin}_{z \in Q} \nabla f(x^k)^T z$   
3    $x^{k+1} = x^k + \alpha_k(\phi_Q(x^k) - x^k)$   
4    $k := k + 1$   
5 end
```

Teoremă

Fie f o funcție diferențiabilă cu gradient Lipschitz și Q mulțimea fezabilă convexă. Pentru pasul $\alpha_k = \operatorname{argmin}_{\alpha \in [0,1]} f(x^k + \alpha(\phi_Q(x^k) - x^k))$, șirul MGC satisface:

$$\nabla f(x^k)^T (x^k - \phi_Q(x^k)) \rightarrow 0 \text{ când } k \rightarrow \infty.$$

Mai mult, dacă f convexă atunci $f(x^k) - f^* = \mathcal{O}(1/k)$.

$$\begin{aligned} \min_{x \in \mathbb{R}^3} \quad & f(x) = x_1^2 + x_2^2 + x_3^2 + (x_1 + 2x_2 - 4)^2 \\ \text{s.l.} \quad & \|x\| \leq 1. \end{aligned}$$

Calculați prima iterație a MGC cu pas constant $\alpha = 1/L$, pornind din $x^0 = [0 \ 0 \ 0]$.



Calculați soluția următoarelor probleme:

- $\arg \min_{x \in \mathbb{R}^n} c^T x \text{ s.l. } l \leq x \leq u$
- $\arg \min_{x \in \mathbb{R}^n} c^T x \text{ s.l. } \|x\| \leq r$



Programare Neliniară: probleme de minimizare supuse la constrângeri de inegalitate

$$\begin{aligned} (POCi :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } h(x) \leq 0, g(x) = 0. \end{aligned}$$

- Mulțimea fezabilă este definită
 $Q = \{x \in \mathbb{R}^n : h_i(x) \leq 0, g_j(x) = 0, i = 1, \dots, p; j = 1, \dots, m\}.$
- Optim-ul global: $f(x^*) \leq f(x), \forall x \in Q.$
- POCi convexă dacă f, h_j convexe pentru $j = 1, \dots, p + g_i$ liniare pentru $i = 1, \dots, m.$



$$\begin{aligned} (\text{POCi convexa :}) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } h(x) \leq 0, Ax = b. \end{aligned}$$

unde f, h_i funcții convexe, $h : \mathbb{R}^n \rightarrow \mathbb{R}^p, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$.



$$\begin{aligned} (\text{POCi convexa :}) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } h(x) \leq 0, Ax = b. \end{aligned}$$

unde f, h_i funcții convexe, $h : \mathbb{R}^n \rightarrow \mathbb{R}^p, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$.

$$\begin{aligned} (\text{SVM :}) \quad & \min_{w, b, \xi} \frac{1}{2} \|w\|_2^2 + \rho \sum_i \xi_i \\ & \text{s.l. } y_i(w^T x_i - b) \geq 1 - \xi_i, \xi \geq 0. \end{aligned}$$



$$\begin{aligned} (\text{POCi convexa :}) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } h(x) \leq 0, Ax = b. \end{aligned}$$

unde f, h_i funcții convexe, $h : \mathbb{R}^n \rightarrow \mathbb{R}^p, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$.

$$\begin{aligned} (\text{Problema Google :}) \quad & \min_x \frac{1}{2} \|Ex - x\|_2^2 \\ & \text{s.l. } \sum_i x_i = 1, x \geq 0. \end{aligned}$$



$$\begin{aligned} (POCi :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } h(x) \leq 0, Ax = b, \end{aligned}$$

unde f, h_i funcții convexe, $h : \mathbb{R}^n \rightarrow \mathbb{R}^p, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$.



$$\begin{aligned} (POCi :) \quad & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.l. } h(x) \leq 0, Ax = b, \end{aligned}$$


unde f, h_i funcții convexe, $h : \mathbb{R}^n \rightarrow \mathbb{R}^p, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$.


- Funcția Lagrange $\mathcal{L} : \text{dom}(f) \times \mathbb{R}^m \times \mathbb{R}_+^p$:

$$\mathcal{L}(x, \mu) = f(x) + \mu^T (Ax - b) + \lambda^T h(x)$$

- μ, λ multiplicatori Lagrange (variabile duale)








Presupunem setul de date $X = \{x^2, \dots, x^m\} \subset \mathbb{R}^n$. Definim un grup (cluster) ca un subset de date pentru care distanțele inter-punct sunt mai mici decât distanțele față de punctele din afara grupului.

Problema: Pentru un K dat, partiționați mulțimea X în K grupuri (cluster-e).



- Putem formaliza folosind vectorii $\{\mu^i\}_{i=1}^K$, unde μ^i reprezintă centrul (prototipul) grupul cu index i .
- Soluție: repartizarea x^i într-un grup și determinarea prototipului μ^i , astfel încât distanțele euclidiene la μ^i sa fie minime.

Pentru un punct x^j fixat, repartizarea rezultă din:

$$\min_{1 \leq i \leq K} \|x^j - \mu^i\|^2$$



Problema *K-Means*:

$$\min_{\mu^1, \dots, \mu^K} \sum_{j=1}^m \min_{1 \leq i \leq K} \|x^j - \mu^i\|^2$$

Reformulăm folosind:

$$\begin{aligned} \min \{a_1, \dots, a_N\} &= \min_s \sum_i s_i a_i \\ \text{s.t. } \sum_i s_i &= 1, \quad s \geq 0. \end{aligned}$$



$$\min_{1 \leq i \leq K} \|x^j - \mu^i\|^2 = \min_s \sum_i s_i \|x^j - \mu^i\|^2$$

$$\text{s.t. } \sum_i s_i = 1, \quad s \geq 0.$$

Problema *K-Means*:

$$\min_{\mu^i \in \mathbb{R}^n, s^j \in \mathbb{R}^K} \sum_{j=1}^m \sum_{i=1}^K s_i^j \|x^j - \mu^i\|^2$$

$$\text{s.t. } \sum_{i=1}^K s_i^j = 1, \quad s^j \geq 0.$$



Problema *K-Means*:

$$\begin{aligned} \min_{\mu^i \in \mathbb{R}^n, s^j \in \mathbb{R}^K} \quad & \sum_{j=1}^m \sum_{i=1}^K s_i^j \|x^j - \mu^i\|^2 \\ \text{s.t.} \quad & \sum_{i=1}^K s_i^j = 1, \quad s^j \geq 0. \end{aligned}$$

- problema este neconvexă în (μ, s)
- subproblemele în μ , respectiv s sunt convexe
- intuiție: algoritm de minimizare alternativă



Algoritm de minimizare alternativă

Cât timp *criteriu oprire* = *FALS*:

1. $\mu_{k+1}^i = \arg \min \sum_{j=1}^m [s_k^j]_i \|x^j - \mu^i\|^2, \quad \forall 1 \leq i \leq K$
2. $s_{k+1}^j = \arg \min \sum_{i=1}^K s_i^j \|x^j - \mu_{k+1}^i\|^2, \text{ s.l. } \sum_{i=1}^K s_i^j = 1, \quad s_i^j \geq 0, \quad \forall 1 \leq j \leq m$
3. $k := k + 1$



Algoritm de minimizare alternativă

Cât timp *criteriu oprire* = FALS:

1. $\mu_{k+1}^i = \frac{\sum_{j=1}^m [s_k^j]_i \|x^j\|}{\sum_{j=1}^m s_{i,k}^j}$
2. $[s_{k+1}^j]_i = \begin{cases} 1 & \text{dacă } i = \arg \min_i \|x^j - \mu^i\|^2 \\ 0 & \text{altfel} \end{cases}$
3. $k := k + 1$



- [1] Christopher Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [2] A. Shapiro, *Introduction to Stochastic Programming*, SIAM.

